



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 知识图谱与推荐算法任务优化及领域应用发展综述
作者: 韩一鸣, 魏国辉
网络首发日期: 2025-11-24
引用格式: 韩一鸣, 魏国辉. 知识图谱与推荐算法任务优化及领域应用发展综述[J/OL]. 计算机工程与应用. <https://link.cnki.net/urlid/11.2127.tp.20251121.1550.006>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

知识图谱与推荐算法任务优化及领域应用发展综述

韩一鸣, 魏国辉⁺

山东中医药大学医学信息工程学院, 济南 250355

⁺ 通信作者 E-mail: bmie530@163.com

摘要: 推荐算法作为当前信息过滤的核心技术, 需要通过知识图谱的语义关联以及结构化知识来解决信息碎片化和可解释性不足的问题。为了进一步促进知识图谱与推荐算法的技术融合, 研究推荐模型性能提升的关键和多领域多技术的发展, 文章按照知识图谱构建与推荐算法结合过程分解为知识图谱模块优化、推荐任务模块优化、多任务模块优化三部分。并从发展历程、优化改进、核心技术等角度详细梳理各模块相关理论和研究成果; 同时迎合当前领域发展趋势, 总结了大模型、医学领域和电商领域应用的最新发展及存在的挑战; 最后对知识图谱与推荐算法现存问题进行总结与展望, 为后续研究提供新的拓展思路。

关键词: 知识图谱; 推荐算法; 知识图谱构建; 多任务学习; 大模型

文献标志码:A 中图分类号:TP391 doi: 10.3778/j.issn.1002-8331.2505-0279

Overview of Task Optimization and Domain Application Development of Knowledge Graph and Recommendation Algorithm

HAN Yiming, WEI Guohui⁺

College of Medical Information Engineering, Shandong University of Traditional Chinese Medicine, Jinan 250355, China

Abstract: As the core technology of current information filtering, recommendation algorithms need to solve the problems of information fragmentation and insufficient interpretability through semantic association of knowledge graphs and structured knowledge. In order to further promote the technological integration of knowledge graph and recommendation algorithm, research the key to improving the performance of recommendation models and the development of multi domain and multi technology, this article decomposes the process of combining knowledge graph construction with recommendation algorithm into three parts: knowledge graph module optimization, recommendation task module optimization, and multi task module optimization. And comprehensively review the relevant theories and research results of each module from the perspectives of development history, optimization and improvement, core technology, etc; Simultaneously catering to the current development trends in the field, the latest developments and challenges in the application of Large Language Models, medical and e-commerce fields have been

基金项目: 国家自然科学基金(61702087); 山东省自然科学基金面上项目(ZR2022MH203); 山东省研究生优质教育教学资源项目(SDYKC2023044); 山东中医药大学教育教学研究课题(实验教学专项)(SYJX2022013)。

作者简介: 韩一鸣(2001—), 男, 硕士研究生, 研究方向为知识图谱; 魏国辉(1983—), 男, 通信作者, 博士, 副教授, 研究方向为医学影像计算。

summarized; Finally, a summary and outlook are provided on the existing problems of knowledge graphs and recommendation algorithms, providing new ideas for future research.

Key words: knowledge graph; recommendation algorithm; construction of knowledge graph; multi-task learning;

Large Language Models

随着时代与技术的发展,互联网信息生成速度也呈指数级增长,面临的主要问题就是信息过载(Information Overload)^[1]。过量的无效数据涌入,稀释了真正有意义的数据,致使在提取目标数据更加困难,大量有助于提升推荐服务质量的用户信息需要进一步的使用和挖掘。而传统的搜索引擎仅仅根据关键词进行信息匹配,无法推荐用户潜在可能感兴趣的项目,过于大众化。推荐算法(Recommendation Algorithms)与知识图谱(Knowledge Graph, KG)作为信息时代的两大核心技术,分别从数据驱动和语义理解维度重塑了获取信息的范式。自推荐算法被提出到应用,已经在商业、医用等领域取得了巨大的成果^[2]。例如,抖音平台广告高度依赖推荐算法,内嵌广告(标签挑战广告、信息广告)利用精准匹配用户兴趣,在广告主投资回报率显著高于传统平台,直播带货率、观众停留时长、优化商品推送都有明显增长^[3],部分店铺销售额度提升30%以上。这充分证明了其研究价值。近年来,知识图谱在自然语言处理领域获得了巨大的发展^[4],其蕴含的大量信息,正好可以解决数据稀疏性的问题。同时清晰的语义路径也可以作为推荐结果的逻辑证明,提高了可解释性。因此,如何更好的将知识图谱与推荐算法结合已经成为目前研究方向的热点^[5]。知识图谱的起源和发展历史最早是在20世纪70年代^[6],而知识图谱作为一个系统化的研究领域,是在2012年谷歌公司明确提出了知识图谱的概念,并构建了一个大规模的知识图谱^[7]后。其核心问题为如何从异构数据中提取结构化知识并实现跨领域推理。

近年来,推荐算法面临冷启动问题的深化与隐私悖论的双重困境,用户行为数据碎片化会导致传统协同过滤难以捕捉瞬时兴趣变化^[8],而欧盟《数字服务法案》对数据最小化原则的强制要求又进一步加剧了数据稀疏性^[9];知识图谱则受限与动态数据融合的计算复杂度,实时更新万亿级别的节点关系导致训练时间呈指数级增长,其多源知识融合中的语义歧义问题使跨领域推理准确率下降至68.3%^[10]。在算法层面,需构建融合因果推荐框架来消除数据偏差导致的“信息

茧房”效应^[11],此外多模态交互带来的异构数据处理难题亟待解决,这些挑战的本质折射出现代信息系统的根本矛盾:如何在保障隐私与效能的平衡中,实现从“数据拟合”到“认知涌现”的范式跃迁。

当前基于知识图谱的推荐算法研究采用构建方式分类法,然而该方法存在两个局限:一是未能充分考虑各功能模块间的协同作用机制,二是缺乏跨领域技术迁移的视角。针对这些问题,本研究通过系统分析2015-2025年的相关文献,创新性地提出了一种模块化分解框架,将现有研究划分为五个核心优化维度:(1)知识表示学习优化;(2)知识推理与补全优化;(3)知识融合与质量优化;(4)知识图谱与用户行为表征融合优化;(5)高阶语义信息聚合优化。同时介绍了当前基于大模型和知识图谱的推荐系统研究成果。相较于传统综述,本文不仅深入剖析了各技术模块在本领域的最新进展,更着重探讨了这些技术在跨学科应用中的创新性迁移与融合。这种多维度的分析框架不仅弥补了现有研究对技术关联性探讨的不足,更为未来跨领域的技术融合与创新提供了系统的理论参考。

1 传统推荐算法研究

传统推荐算法在知识图谱时代仍具有不可替代的价值,其核心优势体现在三个方面:基础方法论、计算效率和场景适应性。作为推荐系统的理论基石,矩阵分解(Matrix Factorization MF)等传统方法为深度学习提供了可扩展的底层架构,其潜在因子思想被扩展用于高阶非线性交互建模。在实践层面,传统算法针对冷启动和稀疏数据优化的策略为知识图谱推荐提供了重要启发。特别值得注意的是,传统算法具有轻量化优势,其计算消耗需求低于知识图谱模型,这使得它们在移动端等资源受限场景中展现出独特的适用性。

1.1 传统推荐算法分类依据及介绍

传统推荐算法依据推荐数据依赖模式可以分为基于内容的推荐(Content-Based Filtering, CBF)和基于协同过滤的推荐(Collaborative Filtering, CF)。CBF主要

利用物品（如文本、标签）或者用户自身（如兴趣）特征进行推荐。CF 则利用用户-物品交互数据（如评分、点击）推荐，而不依赖物品或用户的内容特征。除此之外，还有一种结合多种推荐策略（如 CBF+CF）的混合推荐方法（Hybrid Methods）。

1.1.1 基于内容的推荐

CBF 通过分析用户历史行为数据，构建用户偏好与物品特征之间的映射关系实现推荐其核心思想在于利用自然语言处理、特征工程及相似性度量方法，从用户历史行为数据中提取显式或隐式偏好特征^[12]，同时通过语义分析、词嵌入等技术解析物品的内容属性^[13]（如逻辑回归^{[14][15]}等），最终基于余弦相似度、欧氏距离等度量函数匹配用户与物品的向量化表示以实现推荐^{[16][17]}。然而当前该方法仍然存在许多挑战，首先特征提取的浅层性导致对物品语义理解不足，对模型、视频等内容缺乏有效表征能力；其次，动态偏好建模能力薄弱。难以捕获兴趣波动，而且数据还存在分布复杂，碎片化的特性。针对这些问题，Huang 等人^[18]提出的语义增强推荐算法，保留了传统统计特征可解释性的同时，还利用了预训练模型捕捉长文本的深层语义关联，实验表明该算法在新闻场景推荐的 F1 值对比基线模型提升 12.7%。He 等人^[19]研发的多源信息融合框架则整合用户的社交关系等行为数据，有效缓解了数据稀疏性问题，其 NDCG@10 指标较基线方法提高 19.3%。文献^[20]提出了一种基于高斯混合的模型，该模型使用高斯分布来对推荐系统中各个项目进行聚类，并利用这种混合来拟合数据集中的复杂分布，能够有效处理具有多种分布特性的数据集。此外，基于大型语言模型的内容推荐也正成为新兴方向，例如 SPAR 模型利用 GPT-4 生成用户兴趣摘要，并结合注意力机制动态调整推荐策略，在 MIND 数据集上点击率提升 23%^[21]。综上所述，CBF 研究呈现出从传统匹配向深度融合语义理解的重要转变，当前的研究热点主要集中于利用预训练语言模型、多模态信息融合与因果推断等方法，以提升对用户隐式偏好和复杂项目语义的捕捉能力。同时，融合多源行为数据的混合模型进一步增强了对用户数据分布复杂性的适应能力。未来，CBF 系统将更注重可解释性和因果推理机制的嵌入，以实现更加精准的个性化推荐。

1.1.2 基于协同过滤的推荐

基于协同过滤的推荐算法通过挖掘用户群体或物品在历史交互中的相似性模式，预测未来潜在的兴趣偏好，根据用户-物品评分矩阵为数据基础，分为用户-用户协同过滤和物品-物品协同过滤^{[22][23][24]}。该方法原理灵感最早可追溯至于 Rendle 等人^[25]提出因子分解机（Factorization machines FM）原理：通过不同特征向量之间各自做一次二阶交互来进行特征交互。但是这种方法随着交互的特征数量增加，甚至是三阶特征交互时，效率就会大大下降。对此 He 等人^[26]提出了 NFM（Neural factorization machines）模型，利用神经网络替代 FM 中二阶隐向量内积的部分将两者特征向量通过特征交叉池化层中，再通过神经网络来输出最终值。但是无论是 FM 模型还是 NFM 模型，对于所有的特征交互都是一视同仁，但实际上，不同的特征组合对结果是由差别的，对此，Xiao 等人^[27]结合注意力机制提出了 AFM（Attentional factorization machines）模型，核心思想是在调整两者的权重两两向量交叉之后，与一个注意力分数 α 相乘，动态调整不同特征交叉组合的权重。另外，可扩展性受限于用户与物品规模过量增长。对此，Sarwar 等人^[28]利用矩阵分解将高维评分矩阵降低秩潜在空间，来捕捉用户与物品的隐式特征。近年来，协同过滤还呈现跨学科融合与模型创新趋势，一方面与利用图卷积或注意力机制捕获高阶传播关系，提升推荐效果，同时还结合扩散模型模拟用户偏好演化过程。随着研究的深入，学者们提出了许多优化传统相似度的计算方法，文献^[29]在在计算余弦相似度时引入了权重因子，根据评分强度调整相似度计算。另外，文献^[30]通过减去用户评分的平均值来去除评分尺度差异的影响，提高了相似度计算的精度。文献^[31]结合了时间衰减因子优化了相似度的计算；除了优化相似度的方法，在解决冷启动问题上也取得了进展，文献^[32]提出了一种新的协同过滤方法 DeepMF，通过分层架构对矩阵模型多次细化，将前一层获得的知识作为后续层的输入，从而不断改进预测结果。文献^[33]将生成对抗网络与协同过滤相结合，提出了模型 CFGAN，这种方式生成的用户行为数据，可以很好的解决冷启动问题。文献^[34]使用 Katz 相似性度量和信任网络来计算用户的相似性，这种迭代计算和归一化技术提升了推荐准确性。此外，许多学者将协同过滤与深度学习相结合，利用深度学习提取内容的特征，并融入协同过滤模型中。文献^[35]结合时

基于协同过滤的推荐	Rec ^[18]		下文理解。				问题	维护成本高
	Multi-Source Fusion Rec ^[19]	2024	多源信息融合优化推荐。	Douban Movie, Yelp	SVD, FM	NDCG@10:+8%, RMSE:+5%	矩阵分解, 特征融合	数据预处理和对齐复杂, 计算和存储开销大
	SPAR ^[21]	2024	优化个性化内容推荐。	Netflix Prize, Twitter Stream	BERT4Rec, GRU4Rec	NDCG@10:+18%, Recall@10:+15%	Transformer, 注意力机制	语义路径的设计和选取依赖领域知识
	Item-Based CF ^[28]	2001	基于物品相似度的协同过滤	Amazon Electronics	UserKNN, PopRec	Precision@10:+6%, Recall@10:+5%	协同过滤, 相似度计算	依赖用户行为数据,
	Factorization Machines ^[25]	2010	特征交互建模用于稀疏数据预测	Netflix Prize, Yahoo! Music	SVD, PMF	RMSE:+10%, AUC: +8%	特征交叉, 矩阵分解	通常为二阶特征交互, 高阶交互需要复杂扩展
	Improved UserSim CF ^[24]	2014	改进用户相似度计算, 提升协同过滤精度。	MovieLens-100K, BookCrossing	UserKNN, SlopeOne	RMSE:+7%, Precision@10:+9%	协同过滤, 相似度度量	改善传统基于用户的协同过滤的推荐精度
	New UserSim CF ^[31]	2014	新用户相似度模型, 缓解数据稀疏性。	Epinions, Ciao	TrustMF, SoRec	Precision@10:+11%, Recall@10:+10%	协同过滤, 社交网络	能在新用户行为较少时快速提供推荐
	Improved User-Based CF ^[29]	2015	优化用户相似度, 提升动态场景效果。	MovieLens-1M, Last.FM	UserKNN, ItemKNN	RMSE: + 6%, HR@10: +7%	协同过滤, 时间衰减	改进相似度计算, 引入约束, 提升性能
	Neural FM (NFM) ^[26]	2017	FM 的神经网络扩展。	MovieLens-1M, Frappe	FM, Wide&Deep	RMSE:+12%, Recall@10:+11%	深度学习, 特征交互	引入神经网络增强 FM, 能建模高阶和非线性特征交互
	Attentional FM ^[27]	2017	引入注意力机制加权特征交互	MovieLens-100K, Pinterest	FM, NFM	RMSE:+8%, NDCG@10:+9%	注意力机制, 特征交互	在 FM 基础上引入注意力机制, 自适应学习不同特征交互
	Deep MF ^[32]	2020	捕捉非线性用户-物品交互	MovieLens-20M, Yelp	NMF, AutoRec	RMSE:+9%, NDCG@10:+(10%)	自编码器, 矩阵分解	深度学习方法与传统矩阵分解结合
	ColdGAN ^[33]	2020	用 GAN 生成	MovieLens-	DropoutNet	HR@10:+20%,	GAN, 嵌	解决冷启动问题

基于混合的推荐		用户嵌入，解决冷启动问题。	100K, Douban	, MeLU	Recall@10:+18%	入生成	题，利用生成对抗网络，丰富稀疏数据信息	定，难以收敛，生成的数据质量直接影响推荐效果入生成	
	Trust-Based CF ^[34]	2018	基于信任传播的协同过滤。	FilmTrust, Epinions	SoReg, SocialMF	RMSE:+8%, Precision@10:+9%	信任网络，协同过滤	缓解数据稀疏性和冷启动，增强推荐的可信度	数据获取困难，可能引入噪声
	DL Cold-Start Rec ^[35]	2017	深度学习和 CF 融合	Amazon Book, Netflix	CB-CF, DeepCoNN	RMSE:+7%), HR@10:+12%	深度学习，矩阵分解	深度学习模型学习用户和物品的深层特征	应对冷启动矩需要大量数据，在冷启动场景下优势可能受限
	Spectral CF ^[36]	2018	谱图理论优化协同过滤，	MovieLens-10M, Spotify	LightGCN, NGCF	NDCG@10:+11%, Recall@10:+10%	谱图理论，图分解	能捕捉全局协同信号和潜在社区结构	计算复杂度高，难以扩展到超大规模数据集
	Multi-Feature Discrete CF ^[37]	2020	多特征离散化处理	Taobao, RetailRocket	FFM, DiscreteMF	Precision@10:+14%, Latency: +50%	特征工程，协同过滤	能处理连续特征和非线性关系	特征离散化可能造成信息损失
	Wasserstein CF ^[38]	2020	距离优化物品嵌入分布	MovieLens-20M, Goodreads	WMF, CML	HR@10:+16%, NDCG@10:+13%	Wasserstein 距离，矩阵分解	离，衡量用户或物品分布差异，解决数据稀疏性和噪声	距离计算成本较高，大规模应用时效率可能成问题
	Senti-MVCF ^[39]	2019	生成混合推荐	Amazon Review, Yelp	DeepCoNN, TransNet	F1-Score:+15%, NDCG@10:+12%	情感分析，多视图学习	能更细致地捕捉用户情感偏好	情感分析准确性高度依赖自然语言处理技术
	mo-MultiSource Fusion ^[45]	2020	多源视图融合	Twitter, Instagram	DARec, CF-Emo	Precision@10:+16%, F1-Score:+13%	情感分析，多源融合	能灵活平衡不同来源信息的贡献	调参成本高
	LightGCN ^[43]	2020	简化图卷积网络。	Gowalla, Amazon-CD	NGCF, PinSage	Recall@20:+21%, NDCG@20:+25%	图卷积网络，邻域聚合	简化了 GCN 设计，侧重于邻域聚合，在推荐任务取得更好效果	对图结构数据依赖性，数据稀疏时图构建可能不准确
	Transformer-MVF ^[44]	2023	Transformer 融合多视图增强表示学	Yelp, IMDB	VBPR, MMCF	NDCG@10:+17%, Recall@10:+14%	Transform er, 多视图融合	利用 Transformer 架构强大的序列	自注意力机制计算复杂度高，尤其

习。					建模和特征交互能力		对于长序列数据图融合	
Multi-Objective Hybrid Rec ^[42]	2023	多目标协同过滤优化云数据推荐	Alibaba Cloud, MIND	HybridSVD, MOO-CF	Diversity: +18%, Precision@10: +10%	多目标优化, 协同过滤	多目标优化, 同时优化多个目标	多目标之间存在冲突, 模型设计复杂

1.3 数据集分析与介绍

本节主要介绍一些典型数据集。MovieLens 数据集是推荐系统领域最具影响力的公开数据集之一, 由美国明尼苏达大学 GroupLens 研究小组于 1997 年创建并持续维护。该数据集通过收集用户对电影的评分、标签及人口统计学信息, 为协同过滤、内容推荐、跨模态学习等算法研究提供了标准化测试平台。而该数据集也经历了多次格式升级, 从最初的 dat 后缀文件改为 csv 文件, 并且新增标签基因组, 量化标签与数据的相关性, 支持细粒度内容分析, 同时在升级的过程中将一些隐私化信息进行删除。优势方面, 该数据集标注规范, 多模态扩展性较强, 研究者可以结合外部数据构建跨模态数据集。但是未对实体嵌套进行标注, 影响细粒度推理。

Amazon 系列数据集以商品评论为核心, 并持续更新拓展多维度信息, 新版本的 AMAZON REVIEWS 2023 是由 McAuley 实验室在 2023 年收集的大规模亚马逊评论数据集, 包含了超过 5.7 亿条评论和 4800 万个商品, 涵盖了 33 个不同的类别。数据集特征丰富。但该数据集实体标注不足, 嵌套实体未结构化存储, 仍然在一定程度上影响细粒度推理。不过该系列数据集凭借超大规模以及持续更新, 成为推荐系统与 NLP 研究的核心基准, 在推动工业级算法和支持跨领域任

务中具有极大价值。

Netflix 系列数据集在推荐系统研究中占据核心地位, 主要包括 Netflix Prize 竞赛数据集、Netflix 内容元数据集及 Netflix 评论数据集三部分。但是所有的数据集均未显示标注嵌套实体, 需要依赖外部知识库或 NLP 工具进行补全。另外对于动态内容补全不足。尽管三者 in 实体标注粒度、时效性上各有短板, 却共同构成流媒体推荐研究的黄金三角。未来可结合层级实体抽取在“嵌套实体补全”与“多模态融合”方向突破。

Twitter 数据集作为社交网络推荐研究的重要基础, 该数据集的一个突破性创新在于其动态同步机制, 即数据集会实时反映 Twitter 平台上的内容状态变化, 从而确保评估结果与真实环境的一致性。这种设计极大提升了推荐算法测试的生态效度(ecological validity), 使实验结果更具实际参考价值。Twitter 数据集凭借其多样性和实时性, 为各类推荐算法提供了丰富的训练与验证场景。不同数据类型驱动着不同推荐策略的发展, 并在实际应用中展现出各自的性能特点。但是该数据集数据与结构化知识库在实体表示上存在本质差异, 导致融合困难。另外, 数据集 in 的实体通常以扁平化形式存在, 缺乏层级结构标注, 影响推荐的可解释性和细粒度。各数据集如表 2 所示:

表 2 数据集汇总

Table 2 Dataset Summary

数据集名称	发布时间	包含数据集系列	规模与类型	优点	缺点	引用模型
MovieLens	1997 年	MovieLens 100K	ML-1M: 约 100 万	数据质量高; 用户自	数据时效性有	Ensemble Movie Rec

系列	(初始版本)至今,持续更新	MovieLens 1M	条评分, 6040 名用户, 4000 部电影。	愿提供, 经过清洗	限: 部分经典	[20]
		MovieLens 10M		2. 特征丰富: 除评分	版本数据采集	Improved UserSim CF
		MovieLens 20M	ML-20M: 2000 万条	外, 包含用户属性和	时间较早, 难	[24]
		MovieLens Latest	评分, 138,000 名用	物品属性。	以反映当前用	Improved User-Based
		MovieLens Dataset	户, 27,000 部电	3. 学术基准: 不同规	户兴趣	CF ^[29]
			影, 465,000 个标签	模版本适用于从传统		Neural FM (NFM) ^[26]
			应用	协同过滤到深度学习		Attentional FM ^[27]
				模型的算法验证		Deep MF ^[32]
						ColdGAN ^[33]
						Spectral CF ^[36]
Amazon 系列	2007 年 (斯坦福发布早期版本)至今,定期更新	Amazon Reviews (2014)	Amazon 2023: 5.7154 亿条评论, 覆盖 33 个商品类别。类型: 多模态数据, 包括评分、评论文本、商品元数据	规模巨大且多样: 覆盖品类广泛, 适合研究跨领域推荐和长尾问题。信息丰富: 为构建包含商品多方面属性的复杂知识图谱提供基础。	数据稀疏性与长尾效应显著: 大量商品仅有极少评论。预处理复杂: 需要处理非结构化文本、图像, 并整合多源信息, 工程挑战大。缺乏内容信息: 仅包含评分和时间戳, 部分内容缺少内容特征或用户画像, 构建知识图谱需依赖外部数据源	Wasserstein CF ^[38]
		Amazon Reviews (2018)				HGKR ^[46]
		Amazon Reviews (2023)				ML-KDGMoco ^[47]
		Amazon Product Co-purchasing Network				Content Rec ^[18]
						Item-Based CF ^[28]
						DL Cold-Start Rec ^[35]
						Senti-MVCF ^[39]
						LightGCN ^[43]
						IKEGCL ^[48]
						ML-KDGMoco ^[47]
Netflix 系列	2006 年	Netflix Prize 竞赛数据集、Netflix 内容元数据集 Netflix 评论数据集	超过 1 亿条评分, 来自约 48 万用户对 1.7 万部电影的评价。类型: 评分数据	时间戳精确: 非常适合研究用户兴趣的动态变化和时序模型		KGIN ^[49]
						KGCFRec ^[50]
						P5 ^[51]
						SPAR ^[21]
						Factorization Machines ^[25]
						DL Cold-Start Rec ^[35]
						TALLRec ^[52]
						LLMRec ^[53]
						LLM-Ins ^[54]
						CORONA ^[55]
Twitter 系列	2022	TweetNERD (2022)	超过 34 万条推文, 用于命名实体识别与消歧。其他样本: 规模差异大, 有的数据集推文数量可达 140 亿条。类型: 非结构化文本流	实时性与动态性: 完美捕捉实时热点和用户兴趣的快速演变。与 NLP 前沿结合: 适合研究如何利用预训练语言模型从文本中提取实体和关系以构建知识图谱。	数据噪声大: 推文简短、多口语化、多拼写错误, 需要复杂的清洗和预处理。	SPAR ^[21]
						DL Cold-Start Rec ^[35]
						mo-MultiSource Fusion ^[45]

1.4 传统推荐算法面临问题

传统推荐方法面临的核心挑战可归纳为三个关键维度：多模态数据融合能力不足、动态环境适应性有限以及长尾效应加剧问题。具体表现为：随着用户行为数据从单一评分矩阵向多模态（文本、图像、时序等）演进，传统基于协同过滤或内容匹配的算法难以有效捕捉跨模态的潜在关联特征；其次，动态社交网络环境下，用户兴趣呈现显著的时效性特征，而静态推荐矩阵缺乏实时更新机制，导致模型漂移（Model Drift）问题日益突出。另外，推荐系统普遍存在长尾分布现象，这会导致在召回阶段，嵌入空间会因热门商品的主导作用而产生表征扭曲（Representation Distortion）；在排序阶段，长尾商品的预估准确度会显著下降。除此之外，现有系统普遍存在的“黑箱”特性也制约着实际应用。研究表明，这种可解释性缺失不仅影响用户体验，更会放大算法偏差（Algorithmic Bias）带来的伦理风险。因此，构建具备多模态理解能力、动态适应机制、长尾优化策略以及可解释架构的新一代推荐系统，已成为当前研究的重点突破方向。

2 引入知识图谱的推荐算法优化进展

知识图谱作为一种富含语义信息的外部知识源，能够有效增强推荐系统的性能并克服传统算法的局限性。从技术实现层面来看，知识图谱的构建通常遵循资源描述框架（RDF）标准，采用图结构。基于知识图谱推荐系统总体框架如图1所示

表示方法：节点代表实体，边表示实体间的关系。每条关系边可形式化为三元组 (h, r, t) ，其中 $h \in V$ 表示头实体， $r \in R$ 表示关系类型， $t \in V$ 表示尾实体，构成一个有向图结构 $(h \rightarrow t)$ 。在推荐系统框架中，设用户集合 $U = \{u_1, u_2, \dots, u_m\}$ ，项目集合 $I = \{i_1, i_2, \dots, i_m\}$ 。知识图谱模块则定义为 $G = (V, E)$ ，其中 V 为实体集合， $E \subseteq V \times R \times V$ 为关系三元组集合。系统的核心目标是通过联合建模交互矩阵 Y 和知识图谱 G 中的语义关系，预测用户 u 对未交互项目 i 的偏好概率 $p(u, i | Y, G)$ 。




图1 基于知识图谱推荐系统总体框架

Fig.1 Overall framework of knowledge graph based recommendation system

2.1 基于知识图谱的推荐算法构建流程

目前基于知识图谱的推荐系统构建方法主要分为分阶段构建和并行构建两种方法。

(1) 分阶段构建: 首先通过知识抽取、知识融合等技术构建知识图谱, 然后利用知识图谱嵌入和表示学习将图谱中实体和关系转换为向量表示(这一过程可以看作知识图谱模块任务)。再利用知识图谱嵌入得到的向量挖掘用户-项目的交互数据, 并进行特征融合。最后利用相似度计算, 以及生成的候选项目集进行排序和评分(这一过程可以看作推荐模块任务)。

(2) 并行构建与分阶段构建的区别在于: 将知识图谱实体关系与用户项目交互矩阵同步进行^[56], 然后推荐系统通过用户行为反馈实时更新知识图谱, 形成“数据收集→图谱扩展→推荐生成→反馈迭代”的闭环^[57](这一过程可以看作多任务学习任务)。

为了能够更细致的分析各个模块间的不同优化方式, 本文根据分阶段构建过程, 将优化任务分解为知识图谱模块优化、推荐任务模块优化(多任务学习模块属于第二种构建方法), 可行性如下(注意, 只针对第一种构建方法, 第二种构建方法技术将在多任务学习模块中介绍):

(1) 技术模块的解耦性: 知识图谱模块聚焦于知识图谱本身的构建与优化, 核心技术包括知识融合、知识推理、知识嵌入。这些任务独立于推荐场景; 推荐模块专注于利用知识图谱增强推荐性能, 核心技术包括用户信息挖掘和高阶语义聚合, 这些任务直接服务于推荐目标。因此各模块任务具有独立性, 可以进行分解分析。

(2) 信息流动方向: 知识图谱任务为推荐任务提供输入(如嵌入向量、推理路径), 但反向不影响知识图谱构建。这种单向性支持模块化设计, 符合经典推荐系统的分层架构理论。

(3) 任务粒度的层次性: 知识图谱任务属于细粒度(处理实体/关系级操作), 推荐任务属于粗粒度(处理用户-物品级预测), 这种层次划分与知识表示学习(KRL)和推荐系统研究的传统边界一致。

2.2 优化知识图谱模块的方法

知识图谱模块优化, 旨在通过增强知识图谱的完

整性、准确性和语义关联性, 为推荐算法提供更高质量的结构化知识支撑, 从而提升推荐效果。知识图谱构建过程可以分为知识抽取、知识融合、知识推理、知识嵌入四个过程, 本节将重点介绍后三部分的优化进展。

2.2.1 知识融合与质量优化

知识融合是指对不同来源的异构数据进行对齐与整合, 通过构建统一的语义网络来增强知识图谱的语义关联性和结构完整性。然而, 由于多源数据的异构性, 往往存在噪声冗余和语义歧义问题, 可能导致语言层面的表示差异(如概念冲突)和模型层面的结构差异(如属性类型不匹配)等挑战。首先, 针对这些异构数据, 文献^[46]提出的 HGKR 模型将知识图谱作为异构图进行迭代学习, 并将图神经网络融入知识图谱语义层面。在 ml-latest 数据集上与实验中最佳基线模型对比 AUC 指标高出 0.92%, 召回率高出 0.37%。文献^[58]将知识图谱中异构信息转换为数据导向信息, 利用这种重构的方式, 不仅解决了异构信息的问题, 还减少了大量的冗余节点, 使查询效率提升了 30% 以上。在跨模态语义对齐方面, Wang 等人^[59]等人结合 GraphSAGE、ViT 和 BERT 编码器。Dong 等人^[60]通过多层交互减少模态异质性, 并引入标签交叉模态对齐增强语义一致性。则是利用跨模态特征映射到隐藏空中进行交互, 进而减少跨模态特征之间的差异, 同时增强融合特征的表示一致性。为了解决传统基于相似性匹配方法无法映射复杂语义歧义问题,^[61]提出了一种基于知识图谱检索增强的方案, 该框架利用子图检索和排名优化的方法在模式匹配任务中推荐效率提升 25%; 另外, 特征蒸馏技术 (Feature Distillation) 可以将复杂模型(教师模型)的知识迁移到轻量化模型(学术模型)中, 继而将不同知识源的特征空间里的语义信息对齐, 从而有效整合异构知识, 提升知识融合效率。近年来, Li 等人^[62]提出了 RKDEA 框架, 将预训练的两层图神经网络作为教师模型, 提供关系知识, 最后利用知识蒸馏机制将关系知识从教师模型转移到学生模型, 完成知识对齐。RKDEA 总体架构如图 2 所示:




图 2 RKDEA 总体框架

Fig.2 RKDEA Overall Framework

Wang 等人^[63]提出了一种低频成分对比知识蒸馏 (Low-Frequency Components-based Contrastive Knowledge Distillation LFCC) 框架,旨在解决异构信息中的特征蒸馏性能下降问题。该框架通过提取和压缩教师模型和学生模型的中间特征中的低频成分,并将其对齐到紧凑的空间中,从而中和异构信息的固有特征表示差异。另外,值得一提的是,蒸馏技术还可以解决高性能推荐系统无法长时间在线的问题,即将离线训练的性能强大的教师模型中的知识迁移到在线推荐的简单学习模型中^[64]。文献^[65]提出了一种基于增量蒸馏 (IncDE) 的 CKGE 竞争方法,该方法考虑充分利用 KG 中的显式图结构。并且,为了优化学习顺序,引入了一种分层策略,对新的三元组进行排名以进行逐层学习。通过结合使用层间和层内顺序,将新的三元组根据图结构特征分组到层中。总的来说,蒸馏技术对知识对齐和推荐系统的优化的效果是显著的,是未来提升模型性能的一条重要思路;最后,在质量优化方面, Jiang^[48]等人提出的对比学习框架通过负采样策略降低知识图谱噪声,并引入残差连接缓解图卷

积的过度平滑现象,在亚马逊图书推荐任务中使用 Recall@20 提升 11.4%,同时 F1 分数提高 9.2%。Liu^[66]等人开发的框架创新性地将三元组与描述信息转化为自然语言模板输入到预训练语言模型中,并结合对比学习框架增强长尾实体表征,在 WN18RR 数据集上 MRR 提升了 5.5%。文献^[47]将多级对比学习应用到推荐算法中,使用丢弃随机边的方法加强了知识图谱协作能力。在知识图谱构建时还结合了动量对比和非线性变换的策略,增强了特征信息的质量。综上所述,近年来,知识融合与质量优化研究逐渐从多源数据静态对齐逐步向动态对齐方向演进。同时,在语义统一与跨模态映射中,能够根据生成式语义直接缓解传统方法在复杂语境下的表示鸿沟问题。另外,神经符号结合的方法逐渐成为了处理异构数据知识的主流方式。研究通过引入不确定性量化、公平性约束来应对噪声,确保融合结果在各类场景中的可靠性。这些进展共同推动知识融合从单一性能优化向多维度的新阶段发展。各模型实验结果如表 3 所示:

表 3 知识融合模型实验结果分析

Table 3 Analysis of Experimental Results of Knowledge Fusion Model

模型名称	时间	核心思想	数据集	实验结果	基线模型	优点	缺点
RKDEA ^[62]	2022	基于关系知识蒸馏的实体对齐	DBP15K, DWY100K	在 DBP15K 数据集上,与 KECG 相比, Hits@1 提升显著;	MTransE,	深度融合多跳关系	计算复杂度
					IPTransE, SEA,	路径,能捕获用户-项目间更隐蔽、深层的语义关联	高,且严重依赖高质量的知识图谱数据。
HGKR ^[46]	2023	结合图神经网络和注意力	MovieLens Latest,	在 MovieLens Latest 上 mAP 提升 0.92%,	NFM, CKE,	有效融合知识图谱中多种类型的实体	迭代学习过程可能导致误差
					MKR, KGCN,		

		力机制建模	MOOCCube		RippleNet,	和关系, 能更细粒	累积和传播
						度地建模异构信息	
IKEGCL ^[48]	2023	结合知识嵌入和图对比学习的推荐算法	Amazon-book, Yelp2018	在 Yelp2018 数据集上, Recall@20 提升 11.4%, NDCG@20 提升 10.3%; 在	NCF, LightGCN, KGCN	侧重于通过对比学习来整合和增强知识图谱的表示, 提高泛化能力	对比学习容易引入噪声
Fusion-Mamba ^[60]	2024	利用改进的 Mamba 模型构建隐藏状态空间,	LLVIP, M ³ FD, FLIR-Aligned	在 M ³ FD 数据集上 mAP 提升 5.9%, FLIR-Aligned 上 mAP 提升 4.9%	CFT, CrossFormer, RSDet, SuperFusion	能高效捕获长序列依赖和跨模态的互补信息	推荐系统中的融合机制和稳定性仍需大量实验验证
对齐知识蒸馏 ^[63]	2024	特征对齐知识蒸馏用于大语言模型压缩	GLUE	与 GPT-4 相比, 性能接近, 且远超 DeBERTa, XLNet, GPT-3 等模型	GPT-4, DeBERTa, XLNet	保持较高性能的同时大幅提升推理效率, 易于部署	蒸馏过程存在性能损失, 学生模型的表现上受限教师模型制约
IncDE ^[65]	2024	基于增量蒸馏的连续知识图谱嵌入	ENTITY, RELATION	在 ENTITY 数据集上, 与 Fine-tune 相比, MRR 提升 2.9%-10.6%;	Fine-tune, PNN, CWR	采用增量或差分进化算法, 在动态环境中提供适应性和优化能力。	收敛速度可能较慢, 且不适合处理大规模
ML-KDGATMoco ^[47]	2024	多层次对比学习的知识感知推荐算法	MovieLens, Amazon-books	在 Amazon-books-KG 数据集上, 与 KGAT 相比, 各项指标均有显著提升	SGL, KGCN, SimGCL	结合多标签学习、知识蒸馏、图注意力和动量对比学习, 提升准确性	模型极其复杂, 多个组件的集成使得训练难度大、超参数多, 容易过拟合
KG-RAG4SM ^[61]	2025	知识图谱检索增强生成用于模式匹配	MIMIC, Synthea, CMS, EMED	在 MIMIC 数据集上, 与 Jellyfish-8B 相比, 精确度提 35.89%, F1 分数提 30.50%;	Jellyfish-8B, SMA T 等	为序列推荐提供更丰富、准确的外部知识上下文, 改善生成推荐项的质量。	检索过程引入额外延迟, 系统整体响应时间增加

2.2.2 知识推理与补全优化

知识推理是指利用逻辑规则、分布式表示或神经网络技术, 基于现有实体和关系挖掘隐含关联并推断新三元组的过程; 而补全优化则旨在针对知识图谱的稀疏性和缺失问题进行修正与完善。知识推理主要包含链接预测和时序推理等技术。首先是链接预测, 通过已有数据推断实体之间缺失的关系或预测未来可能形成的关系链接。目前比较流行的方法是: 利用知识表示学习将实体和关系映射到向量空间(前节已经介

绍, 本节不再概述), 然后利用张量分解技术将高维数据(张量)分解成一组低维数据, 实现预测。与传统矩阵分解不同, 张量分解最终会得到一个核心张量和一组因子矩阵的乘积, 这种分解有助于发现数据中潜在结构, 最终结合评分函数推理出新三元组信息。Nickel 等人^[67]首先提出基于张量分解的方法对关系数据建模的模型 RASCAL, 能够在实体和关系维度表示较大时也能正确拟合张量, 但模型未对信息进行抽取、压缩, 损失了泛化性, 会出现过拟合的现象。对此,

Yang 等人^[68]提出 DistMult 模型通过减少参数数量缓解该现象,但是由于在实体表示函数时不区分主语和宾语,导致模型智能表示对称关系,不过性能仍然远超 RASCAL 模型。考虑到 DistMult 模型只能解决对称关系的问题,Trouillon^[69]等人提出 ComplEx 模型,沿用了 DistMult 模型基本框架,并使用了一组共轭复数分别作为主语和宾语的表示,使得模型既能够表示对称关系,也可以表示反对称关系。与上述模型将三维张量采用二维张量分解处理的方式不同,Balažević 等人^[70]提出的 Tucker 模型采用三维张量进行分解。本质上来讲是将一组二维张量通过线性组合成为了一个关系的“二维张量”。虽然 Tucker 模型具有强大的性能,但是随着张量维度的增加,参数数量也会暴涨,导致整体复杂度上升,又会出现过拟合现象,因此直接使用 Tucker 模型难以满足实际需求。对此,在 2025 年,Yue^[71]等人提出了双层张量模型 TUTR,在外层利用 Tucker 分解将原始知识图谱张量分解为核心张量和分量矩阵,内层利用张量层,对核心张量进行重构。其命中率(Hit@1)指标达到了 20%,相比最先进的基线模型,速度提升了 9.3 倍。该模型首次提出四维度张量建模(实体×关系×实体×时间戳),也解决了时序知识图谱(Temporal Knowledge Graph, TKG)中关系动态变化的预测难题。总的来说,大大推动了相关领域的技术进步和发展。

随着 TKG 不断发展,时序推理也成为了研究的热门,时序推理是指通过捕捉时间维度的上下文依赖关系,推断过去事件的影响、预测未来趋势或补全 TKG 中的缺失信息。目前面临的主要问题是:连续采样导致相关事实丢失、新兴实体缺乏历史记录等问题。针对这些问题,Liu 等人^[72]通过融合大语言模型和时序特征提出了 FL-Evo 模型。实验结果表明,该模型在 Hit@3 上提高了 3.97%,在 Hit@10 提高了 4.07%,并且显著的对缺乏先验记录的新推理性能。另外,知识图谱模块在某些特定领域也会面临构建知识图谱的质量较低的问题,尤其是在冷门领域,例如特殊病症等,信息采集或挖掘都有一定的困难。为了应对这种情况,文献^[73]提出了一种项目关系学习的策略,利用数据增强的方式,不断生成未知项目和相互关系,能够很好的丰富知识图谱内容,提升知识图谱的质量,从而提升推荐性能。类似的,文献^[74]从分层角度设计了增强知识图谱嵌入的策略,旨在解决任务中数据有限的弊端,优化了负采样机制,大大提升可 Few-shot 场景下的连接预测准确率。综上所述,知识推理与补全优化不再局限于传统张量分解或表示学习,而是通过指令微调与思维链技术实现对复杂语义和时序逻辑的推断,通过引入可微规则推理和符号约束,在多个场景中实现对动态知识的结构化补全与一致性验证。

各模型数据集,实验结果如表 4 所示:

表 4 知识推理模型实验结果分析

Table 4 Analysis of Experimental Results of Knowledge Reasoning Model

模型名称	发表时间	核心思想	数据集	实验结果	基线模型	评价指标	优点	缺点
DistMult ^[68]	2015	双线性映射建模关系	WN18、FB15k	在 FB15k 数据集上 Hits@10 为 54.7%	RESCAL, NTN, TransE	Hits@10, MRR	将关系矩阵限制为对角矩阵,参数量大,训练和预测速度极快	无法处理常见的非对称关系,适用性受限
ComplEx ^[69]	2016	复数嵌入建模对称和反对称关系	WN18、FB15k	在 FB15k 数据集上 Hits@10 为 69.2%, 优于 DistMult	DistMult, RESCAL, HoIE	Hits@10, MRR	能有效建模对称与非对称关系,提升了关系表达的灵活	模型解释性较差。复数空间的运算相对抽象

		性					
Tucker 分解	2019	建模知识图谱三元组	WN18、	在 FB15k-237 数据集	DistMult,	MRR,	核心张量实现参数复杂度高, 算和存储开销较大
			FB15k、	上 MRR 为 0.358,	CompLEx,	Hits@1,	
TuckER ^[70]			WN18RR、	优于 CompLEx	Simple	Hits@3,	多任务学习。
			FB15k-237			Hits@10	
两层张量分解建模时间	2025	知识图谱	ICEWS14、	在 ICEWS14 数据集	BTDG,	Hits@1,	引入了新的分解方式或结构, 升模型表达能力和效率
			ICEWS05-15 等六个数据集	上 Hits@1 为 20%, 优于 BTDG	TNTCompLEx 等	Hits@3, Hits@10, MRR	

2.2.3 知识嵌入学习优化

知识嵌入学习优化的核心目标在于增强低维向量空间的语义表征能力, 以提升链接预测、三元组分类等下游任务的性能。其关键挑战在于: 如何在连续向量空间中精确建模实体与关系间的复杂语义模式(包括对称性、传递性和层次性等特性), 同时有效应对数据稀疏性、计算效率和多源异构融合等实际问题。该方法的经典模型有 Trans 系列, 基本原理为, 在满足一定条件下, 头实体 h 、尾实体 t 和关系 r 向量之间存在着数学关系, 即 $h+t \approx r$ 。据此设定了一个打分函数, 该函数被定义为在 $L1$ 范围或 $L2$ 范围约束下的 $h+r$ 和 t 之间的距离。TransH^[75]模型为了解决 TransE^[76]模型难以适用一对多或者多对一关系的处理问题, 提出了一种新的思路。将不同关系看作是在不同超平面上的操作, 通过引入超平面的正交向量和偏移向量, 对实体向量进行了变换, 从而适应多种关系。TransR^[77]则是引入了更加复杂的空间投影机制, 将实体映射到特定关系空间, 有效处理不同的关系集。TransE^[76]、H^[75]、R^[77]模型都是使用固定矩阵来表示实体和关系, 但这样忽略了知识图谱中的异质性和不平衡性, TranSparse^[78]模型则是引入自适应稀疏转移矩阵来改进图谱的嵌入表示, 能够根据实体的不同特性进行动态的调整。然而 Trans 系列模型仍面临着技术参数过多, 且实体表示之间关联性较小的问题, 对于大型知识图谱的运用实际效果不佳。对此文献^[79]将知识图谱与图注意力网络相结合提出了模型 TransD-GAT, 该模型有效减少了实体的投影数量, 并加强了实体之间的关联性。在现阶段发展中的趋势, 许多研究学者将实体、关系使用不同的几何变换, (旋转、缩放、反射、剪切

等)映射到向量空间, 并利用不同程度的几何变化表示不同的关系, 进而优化知识图谱模块的性能。PairRE模型^[80]将每个关系由一对向量表示 (rH, rT), 分别对应头实体和尾实体的映射向量, 该模型还通过 Hadamard 乘积(点积)来计算关系向量。这些处理方式能更加灵活的调整损失函数中的余量以及处理不同类型的复杂关系。文献^[81]中利用自对抗负采样的嵌入方法 RotatE, 将实体和关系映射到复数向量空间, 并将关系定义为从实体到尾实体的旋转, 通过复数向量的不同旋转变化, 更加清晰的捕捉关系之间的语义信息, MRotatE^[82]则是在 Rotate 基础上, 为了优化目标添加了实体旋转的约束, 用以处理多重折关系(multifold relations)。另外, 该模型还充分利用三元组特征, 使得它能够同时建模和推断多种关系模式。但是 RotatE 模型仅有一个旋转平面, 这种旋转极有可能造成两个旋转轴重合, 致使系统无法通过欧拉角描述旋转状态, 即万向节锁死现象。为此, 文献^[83]提出了 QuatE 模型, 利用四元数的几何特性构造了两个旋转平面, 不仅解决了万向节锁死现象, 也丰富了实体与关系的语义表示。HAKE 模型^[84]结合模数部分和相位部分的特性, 实现了在极坐标系下的旋转公式重构, 其中模数部分(径向坐标)用于表示实体的层次结构, 相位部分(角坐标)用来区分相同层次中的不同实体。目前, 单一的几何表示法无法捕捉高级本体视图和细粒度视图两种图之间的结构差异, 对此 Huang 等人^[85]提出了 Concept2Box 模型, 通过将实例和概念与几何对象联合嵌入来学习双视图知识图谱表示, 并设计了一个新的度量函数来预测向量之间的距离。其模型构架如图 3 所示。




图3 Concept2Box 总体框架

Fig.3 Concept2Box Overall Framework

综上所述,知识嵌入学习优化研究逐渐从单一几何表示向多几何融合、结构语义协同等方向深入发展。近年来,借助大语言模型与知识嵌入的协同成为关键趋势,通过借助生成式预训练技术注入外部常识与逻辑约束,有效缓解长尾实体的稀疏表征问题,并在链接预测任务中显著提升零样本和少样本泛化性能。此

外,面向超大规模动态知识图谱的嵌入技术强调效率与扩展性,包括使用哈希投影、量化编码与增量旋转编码策略,在压缩参数的同时能够继续保持嵌入质量,进一步推动知识嵌入发展。各模型数据集,实验结果如表5所示:

表5 知识嵌入模型实验结果分析

Table5 Analysis of Experimental Results of Knowledge Embedding Model

模型名称	发表时间	核心思想	数据集	实验结果	基线模型	评价指标	优点	缺点
TransE ^[76]	2013	几何平移操作建模	WN18、FB15k	相比 RESCAL, Hits@10 提高 6.7%	RESCAL	Hits@10、MRR	模型简单、计算高效,提供了基础框架	难以处理复杂关系建模
TransH ^[75]	2014	不同关系对应的几何操作建模	WN11、FB15k	相比 TransE 模型, Hits@10 提升 8.4%	TransE、NTN	Hits@10、MR、MRR	初步解决复杂关系问题。引入关系特定的超平面	表征能力有限,对某些复杂关系建模不够精细
TransR ^[77]	2015	不同空间几何操作建模	WN18、FB15K	相比 TransE 模型, Hits@10 提升 2.6%	TransE、TransH	Hits@10、MR、Accuracy	显著提升模型表达能力。为每个关系定义特定的向量空间	参数急剧增加、计算开销大,且易出现过拟合
TransSpars ^e ^[78]	2016	自适应稀疏转移矩阵	WN18、FB13、FB15k	与 TransE 模型相比, Hits@10 提升 3.9%	TransE、TransH、TransR	Hits@10、MR	自适应稀疏投影,缓解过拟合	稀疏矩阵的操作稠密矩阵复杂,计算更高要求

RotateE ^[81]	2019	复数向量 空间旋转	FB15k、 FB02k- 237、 WN18RR	与 ComplEx 模型 相比, Hits@10 提 升 4.3%, MRR 提 升 1.8%	ComolEx、 TransE、 DisMult	Hits@10、 MR、MRR	能自然建模对称、 反对称、逆反和组 合关系。	计算复杂度 相对较高
Quate ^[83]	2019	四维空间 旋转捕捉 关系	WN18、 FB15k、 WN18RR、 FB15k-237 WN18RR、	与 RotateE 模型相 比, Hits@10 提升 3.2%, MRR 提升 2.0%	ComolEx、 RotatE、 DistMult	Hits@10、 MRR	能捕获更复杂的语 义交互, 具有比复 数空间更强的表征 能力。	参数数量和 计算复杂度 进一步增加
HAKE ^[84]	2020	极坐标旋 转公式重 构	FB15k- 237、 YAGO3-10	在 FB15k 数据集与 TransE 模型相比 Hits@10 提升 8.1%	TransE、 DistMult、 RotatE	Hits@10、 MRR	能有效区分处于不 同语义层次的实体	模型解释和 训练相对复 杂
PairRE ^[80]	2020	自适应调 整损失函 数	ogbl- wikikg、 FB15k、 FB15k-237	在 FB15k 数据集与 TransE 模型相比 Hits@10 提升 15%	TransE、 DistMult、 HoleE	Hits@10、 MRR	能更好地处理复杂 关系, 在大规模知 识图谱上表现优异	参数量相较 于双曲模型 等仍有优化 空间
HGKR ^[46]	2023	基于异构 图迭代图 学习	MovieLens Latest、 MOOCube 数据集	在 ml-latest 数据集 上的 AUC 和召回 率分别比最佳基线 高出 0.92%和 0.37%	NFM、CKE、 KGCN、 RippleNet、 KGAT	AUC、 Recall	能同时利用知识图 谱中的结构、语义 和属性信息, 生成 更丰富的实体和关 系表示。	需要处理大 规模图的扩 展性问题。

2.2.4 知识图谱模块优化总结

前三节内容实际描绘了一个完整的知识图谱处理流程, 可以形象地理解为“数据处理”、“补全优化”、“拓展优化”的三层架构。它们共同的目标是提升推荐系统中知识图谱模块的质量和效用, 但各自处于不同的技术层面, 解决不同阶段的核心问题。首先知识融合与质量优化是知识图谱构建的“原料处理”阶段。其核心是解决多源异构数据的整合, 以及处理噪声、冗余、语义歧义、实体对齐等问题。如前文中提到的跨模态语义对齐、知识检索增强和知识蒸馏等技术, 都是质量优化的高级手段。而产出的高质量统一化图谱也是后续的基础和前提。知识推理与补全优化则是在其基础上实现图谱的扩展阶段, 它关注的是知识的“深度”和“动态性”。即如何通过算法发现隐藏的三元组(链接预测); 如何理解时间演变规律(时序推理); 如何利用规则或外部知识(如 LLMs)进行逻辑推断等核心技术。而知识嵌入学习优化是进行深度语义表征的阶段。其核心是将图谱中的符号化知识映射到低维连续向量空间, 它关注的是知识内部潜在的语

义结构。而需要区分的则是知识推理与补全优化和知识嵌入学习优化在研究焦点方面, 前者聚焦于如何从已知向未知推理, 如生成新三元组、预测链接等, 偏重与应用层技术。而后者则是聚焦于优化向量表示, 为下游任务提供基础, 更加偏重于基础层技术, 如空间映射、评分函数设计等。两者技术互补, 相辅相成并非完全独立的两个部分, 不过并非所有的推理都依赖于嵌入学习, 而分节讨论有助于明确各自的研究范畴。另外, 当前研究也在趋向一体化, 比如大语言模型既增强嵌入语义来解决长尾问题, 也能够支持复杂逻辑推理。

2.3 优化推荐任务模块的方法

推荐任务模块根据推荐流程可以分为利用知识图谱嵌入挖掘用户行为表征、高阶信息聚合、相似度计算, 预测函数评分排序四部分, 本文将重点剖析这两个关键环节的最新研究进展和技术挑战, 包括基于图神经网络的表征学习方法和多跳邻域信息聚合策略等, 而对相似度计算和评分排序等相对成熟的技术则不做赘述。

2.3.1 挖掘用户行为表征优化

挖掘用户行为表征是指通过融合用户行为数据（如浏览、点击、购买等）与知识图谱中的结构化语义信息（如商品属性、品牌关联等），将用户在交互过程中产生的复杂行为模式抽象为可计算的向量化表示。对此，文献^[86]提出了 AKGE 模型，通过结合知识图谱和拓扑结构来高效挖掘用户行为表征。其中运用了高阶子图提取技术，自动提取和链接用户-物品的高阶子图，捕捉多跳关系语义，该模型还通过限制子图的范围，提高语义密度。另外，图神经网络可以通过图卷积和注意力机制提取行为特征。文献^[50]提出的 KGCFREC 模型使用用户-项目交互矩阵构建了用户-项目交互图，并与知识图谱结合构建双重卷积神经网络，分别可以提取协同信号（用户的行为模式）和语义信号（物品的属性关联），这种方法在 MovieLens-1M 数据集上 AUC 提升 3.2%。文献^[87]则是将多注意力机制应用于群组推荐中的深度学习方法。考虑到单一的注意力头部可能会稀释个别信号。文献^[88]采用了 15 个平行的注意力层，每个头部的维数降低，总的计算代价则与单头注意力相似。文献^[89]则在使用注意力机制的基础上，采用了对藕的思想，即从实体头部和实体尾部两个方向分别计算关系对邻居权重的影响。文献^[90]中提出了一种双图注意力推荐模型 SKGAT 模型，该模型利用用户的社交网络图和项目知识图谱分别与用户-项目交互图融合处理得到两种协同图，再各自进行自注意力机制处理，融合后得到用户和项目的表征向量。

另外，知识图谱中可能会包含大量粗粒度类别，对于实体刻画精度较低，尤其是在经过知识图谱嵌入后。实体及向量间的关系就会越复杂，挖掘任务也会变得困难。对此 Shimaoka 等人^[91]提出了细粒度实体分类（Fine-grained Entity Typing FGET）任务，为图谱中的实体提及赋予具有层次结构的细粒度语义类别。与 NER 序列标注任务不同，FGET 一般使用有层级的多标签分类任务处理实体。但是传统的任务忽略了实体间内部关系，类似一种独立的方法进行预测。现有研究中，主流方法假设细粒度实体分类数据

具有欧氏空间特性，这一假设限制了模型对抗标签噪声的能力。对此，Jin 等人^[92]利用双曲空间中精炼提及编码以消除噪声干扰，最终基于优化后的编码完成 FGET 任务。为了解决交互细粒度意图建模不足，文献^[93]提出了一种基于知识图谱的可视化推荐框架。其首次将知识图谱嵌入技术应用于可视化推荐。通过知识图谱的语义路径提供推荐理由，突破了黑箱模型的限制，并且整合数据特征、数据列和可视化设计，构建了细粒度关系网络。不过其嵌入质量依赖训练数据的覆盖度，对于小众图标类型效果会有折扣。文献^[49]中 KGIN 模型将交互意图建模为知识图谱关系注意力组合，并通过注意力机制动态分配不同关系权重，形成意图表示，并且这些意图之间通过正交约束保持独立性。同时该模型还整合了多跳关系路径的语义。文献^[94]改进了多粒度注意力机制，文献里提出的 FIRE 模型在用户对实体偏好和用户意图中构建了两级注意力机制，在 Yelp 数据集上，F1-score 提升 2.5%。相较于传统二元关系事实，n 元关系知识图谱（n-ary Relational Knowledge Graphs, NKGs）由包含两个以上的多元关系实体构成，但是当前 NKGs 构建仍停留在粗粒度层面，对此 Luo 等人^[95]提出了 TEXT2NKG 框架，一种面向 n 元关系知识图谱构建的细粒度多元关系抽取方法，结合异构有序融合（hetero-ordered merging）与输出合并（output merging）技术，实现对不同元数关系的细粒度抽取。综上所述，当前研究已超越简单的特征拼接，转向对行为-知识交叉语义的深度解析与动态建模。该领域的研究聚焦于精细化与细粒度建模、多模态知识融合、可解释性与因果推理等方面。尤其是细粒度与多粒度意图建模显著深化，层次化实体类型识别（FGET）与多粒度注意力相互配合，既在实体层面实现语义精细化，又在意图层面区隔用户不同动机，有效缓解行为稀疏和语义模糊问题。这些方面使得用户行为表征优化能够更好地应对真实场景中的复杂信息，提升推荐系统的性能和用户体验，同时也增强了系统的可信度和合规性。各主要模型数据集，实验结果如表 6 所示：

表 6 实验结果分析

Table6 Analysis of Experimental Results

模型名称	发表 时间	核心思想	数据集	实验结果	基线模型	优点	缺点
------	----------	------	-----	------	------	----	----

KGIN ^[49]	2021	基于知识图谱的用户意图网络建模	Amazon-Book、Last-FM、Alibaba-iFashion	在 Amazon-Book 数据集上相比 KGAT, Recall@20 提升 13.44%	KGAT, KGNN-LS, CKAN, R-GCN, MF	通过显式建模用户意图来增强知识图谱推理	模型复杂度较高
KGCFRec ^[50]	2024	结合知识图谱和协同过滤的双通道信息传播与聚合	Amazon-Book、Last-FM、Alibaba-iFashion	在 Alibaba-iFashion 数据集上相比 KGAT, Recall@20 提升 11.6%	KGAT, KGNN-LS, CKAN, MF, CKE	将知识图谱关系信息更好融入图协同过滤框架	对知识图谱的质量和完整性依赖较强
FIRE ^[92]	2022	特征交互与意图感知注意力网络的知识增强推荐	Last.FM、Dianping-Food、MovieLens-1M	在 Last.FM 数据集上相比 KGIN, AUC 提升 1.41%	CKE, PER, RippleNet, KGCN, KGNN-LS, KGAT, CKAN, KGIN	系统性地识别和缓解推荐系统中的各种偏差	牺牲一定推荐准确性, 需要精细的权衡策略
DsMtGCN ^[88]	2021	方向敏感的多任务知识图谱补全框架	FB15k-237、WN18RR	在 FB15k-237 数据集上相比 CompGCN, MRR 提升 0.008	TransE, Complex, RotatE, ConvE, DistMult, ConvKB, ConvR, R-GCN, SACN, VR-GCN, KBGAT, CompGCN	动态捕捉用户兴趣变化并同时优化多个目标	动态模型训练复杂且不稳定
HMGC ^[95]	2021	层次多图卷积网络用于细粒度实体类型分类	FIGER、DBpedia	在 FIGER 数据集上相比 CUTE, Mi-F1 提升 1.7%	CUTE, MuLR, FIGMENT	通过分层或多尺度结构捕获图中从局部到全局的复杂模式	模型结构复杂, 训练难度大。

2.3.2 高阶语义信息聚合优化

通过知识图谱中相关用户和项目集合的向量信息以及映射的特征交互进行推荐预测, 得到的准确率是较低的, 并且各个实体、实体与边之间还具有潜在的关联性。因此, 目前许多研究学者会利用知识图谱或图结构中多跳邻域(例如二阶、三阶节点)相关联的信息, 聚合生成更丰富的用户或项目表示。而具体优化聚合思路主要从三个步骤出发, 领域扩展: 从用户或项目的直接关关节点出发, 逐级扩展到多跳领域, 从而获取到高阶语义联系。特征聚合: 对于每个节点, 使用注意力机制等方法聚合邻居间相关特征, 并生成该节点的高阶表示。递归传播: 将多跳邻居特征分别

聚合到目标节点, 并结合之前聚合的高阶表示, 最终整合得到高阶结构信息。RippleNet^[96]模型将用户 U 的历史兴趣集作为图谱中的种子实体, 然后按领域扩展形成多个波纹集 S_{ku} , 也就是用户实体的相邻三元组集合。这些集合与项目嵌入迭代交互, 获取用户与项目的信息表示, 一起聚合得到高阶的用户嵌入信息, 最终通过用户和项目的嵌入向量来计算预测概率。其中算法中提出了一种偏好传播技术, 分别将项目 v 与用户 u 相邻波纹集 S_u 的头部 h_i 和关系映射矩阵 R_i 进行比较, 使用 softmax 函数归一化, 计算出各个相关权重概率。RippleNet 的总体框架如图 4 所示。




图 4 RippleNet 总体框架

Fig.4 RippleNet Overall Framework

但是 RippleNet 模型对于关系特征的关注度较弱，并且关系的嵌入层积矩阵很难被训练捕捉二次响应，同时纹波集随着指数 k 的增加，可能会出现不可预测的变化，会使得计算量大大增加。针对上述问题，文献^[97]提出了 KGCN 模型，首先定义集合为项目邻域的实体节点以及链接它们的关系映射矩阵。并定义了一个函数来计算用户对于关系评估的分数，然后使用用户关系分数计算得到周围的标准化用户得分

近年来注意力机制也在信息聚合时起到关键作用，文献^[98]使用注意力网络和神经协同过滤直接从数据中学习聚合策略，当前比较流行的方法是改进图注意力网络传播节点特征，将目标节点及其领域节点注意力权重引入到动态卷积层，动态聚合多个并行卷积核自适应地调整卷积参数，实现了更高效的特征聚合和相似节点的增强表示。Ting 等人^[99]提出了一种基于注意力融合机制的 GTF-Net 模型，通过多头交叉注意力模块动态地将局部几何特征与全局物理一起聚合。将

梯度误差的标准偏差降低了 85.9%和 23.8%。文献^[100]中提出了一种新的知识图扩散模型推荐 DiffKG。该模型将生成扩散模型和数据增强范式相结合，这种集成也有助于知识感知项语义和协作关系建模之间更好聚合。另外，文献^[101]将高阶特征交互与知识图谱匹配，并利用门控循环单元加强对用户的偏好关注。同时，利用交叉学习来学习项目与实体间高阶特征。综上所述，目前研究已从简单邻域聚合演进为对多跳路径的语义选择、动态权重分配与结构自适应融合的深度建模。首先，结构感知的高阶语义传播机制在不断深化，在控制计算复杂度的同时能够更精准地捕捉用户-项目间多跳依赖。同时，注意力机制与自适应卷积也在进一步融合，包括使用多头交叉注意力整合局部与全局特征，以及借助动态卷积核调整聚合参数。未来，门控循环与交叉学习机制将被广泛用于高阶特征交互。这些技术将共同推动从局部领域聚合走向全局语义推理。各模型数据集，实验结果如表 7 所示：

表 7 信息聚合实验结果分析

Table7 Analysis of Information Aggregation Experiment Results

模型名称	时间	核心思想	数据集	实验结果	基线模型	评价指标	优点	缺点
RippleNet ^[96]	2018	偏好传播机制融合知识图谱	MovieLens-1M, Book-Crossing, Bing-News	MovieLens-1M 数据集上 AUC 提升	CKE, SHINE, DKN, PER, LibFM, Wide & Deep	AUC, Accuracy, Precision@K, Recall@K, F1@K	能够捕获用户的长距离兴趣偏好，并提供推荐路径的解释	兴趣传播路径的选择和稀疏性可能影响效果
				2.0%-40.6%, Book-Crossing 数据集上 AUC 提升 2.5%-17.4%,				
KGCN ^[97]	2019	图卷积网络结合知识图谱	MovieLens-20M, Book-Crossing, Last.FM	MovieLens-20M 数据集上 AUC 提升	SVD, LibFM, LibFM+TransE, PER, CKE, RippleNet	AUC, F1	通过聚合项目在知识图谱中的多跳邻居信息来丰富项目表示，提升推荐的准确性	对知识图谱的完整性依赖较高
				4.4%, Book-Crossing 数据集上 AUC 提升 8.1%				

KRGAT ^[98]	2024	图注意力网络结合知识图谱	自建旅游数据集	P 提升 5.73%, R 提升 4.42%, AUC 提升 1.42%	GAFM, GFM, KGFCN, KGFM, GCN	P, R, AUC, Recall@K, HR@K	自适应地强调知识图谱中用户对偏好语义信息, 提升表示能力。	计算开销相对较大
		知识图谱扩散模型结合数据增强	Last-FM, MIND, Alibaba-iFashion	Last-FM 数据集上 Recall@20 提升 14.4%, MIND 数据集上 Recall@20 提升 51.7%,	LightGCN, SGL, CKE, KTUP, KGNN-LS, KGCN, KGAT, KGIN, MCCLK,	Recall@N, NDCG@N	引入扩散模型来增强知识图谱表示	模型训练复杂且耗时
		图注意力与 Transformer 融合网络用于自适应网络划分	贝塞尔函数案例, 光波导案例	贝塞尔函数案例梯度误差标准差降低 85.9%,	Scikit-FEM (skFem)	MSE, Accuracy, F1-Score	实现快速收敛和高精度, 平衡训练时间、推理速度和模型性能	具有一定的计算成本

2.3.3 推荐任务优化总结

在挖掘用户行为表征优化中, 技术演进路径可以归纳为三部分: 首先在架构上逐渐从线性交互或浅层网络结合转化为图神经网络深度融合架构, 实现了数据源层面的本质关联。在机制深化方面, 多头注意力、对藕注意力以及双图注意力开始不断创新改进, 差异化地捕捉用户行为中不同特征。另外为了克服传统知识图谱嵌入中粗粒度类别导致的语义模糊问题, 引入了细粒度实体分类与用户意图建模, 将用户的一次交互行为解构为多个意图驱动。在高阶语义信息聚合优化部分, 其优化主要体现在从显式路径到隐式路径的扩散。比如偏好传播中显示多跳路径交互转变为当前生成式扩散模型, 通过噪声注入与去噪过程来隐式地学习知识图谱上的语义扩散规律, 不仅能聚合现有信息, 还能推理出潜在的、未直接关联的语义。另外还有聚合过程中的动态性与自适应性。两节内容前者是侧重于“局部”的精准刻画, 即用户与项目直接关联的语义。后者则是侧重于全局的上下文增强, 通过多跳邻居提供补充信息。

2.4 多任务学习模块优化方法

多任务学习是一种联合优化推荐任务和知识图谱补全任务的方法, 其核心思想在于: 知识图谱的结构化语义信息和推荐系统的行为数据是有互补性的, 通过交叉压缩单元 (Cross&Compression Unit) 将知识

图谱嵌入模块损失函数的结果结合到推荐算法的目标函数中, 推荐模块也能够再对知识图谱嵌入模块提供响应的反馈, 通过这种框架实现信息融合与知识迁移, 能够更好的结合两种任务。目前面临的问题有: 交叉压缩单元部分需要优化计算效率; 辅助标签 (Auxiliary Labels) 应用不足, 导致负迁移 (Negative Transfer) 问题; 同时优化两个任务时一个任务性能会伴随另一任务上升而下降, 也就是跷跷板现象。对此本节从这三部分的优化进行介绍。

2.4.1 多任务学习交叉压缩单元优化

在早期的研究中^[102], 任务关系被认为是构建知识图谱前需要掌握的必要技术, 也就是知识图谱先验知识, 尤其是在进行知识图谱任务与推荐任务并行构建时。而在文献^[103]中对此进行了研究, 其假设了任务之间的相似性是已知的, 并设计了正则化器同时学习多个任务。但是先验知识并不总是可用的, 因此, 文献^[104]提出了超越历史样本的自动任务关系发现, 通过对关系的自动挖掘, 进一步提升了知识图谱构建的质量。在训练样本时, ^[105]添加了元数据来探索任务之间的正相关性, 也减少了对先验知识的依赖。另外, 在交叉压缩单元方面, Wang^[106]等人首次提出端到端框架, 通过交叉压缩单元 (Cross&Compression Unit) 实现推荐任务与知识图谱嵌入交互。通过这个交叉压缩单元, MKR 模型可以自适应的调整知识转

移的权重,并学习两个任务之间的相关性。但是需要注意的是,在模型训练时,由于三元组来源是知识图谱,因此全部为正样本,负样本只能人工构造。

Dong^[107]等人在 MKR 模型基础上提出 Ripp-MKR 模型,引入 RippleNet 模型的偏好传播机制,利用波纹扩散捕捉高阶语义关联。但并未优化交叉压缩单元的计算效率。对此,Yang^[108]等人提出 MAPKR 模型,在交叉压缩单元前增加基于图神经网络的潜在特征共享层,通过归一化内积操作提升特征表示的区分度。但该模型处理多模态数据具有局限性。而 Fang^[109]等人提出的 FLFM-MKR 模型采用因子分解机

(FLFM)整合知识图谱中多模态特征,并通过跨模态注意力加权实现异构数据对齐。^[110]等人提出的 MMSS-MKR 模型优化了交叉压缩单元偏置项来降低时间复杂度,并引入时序注意力网络捕捉用户短期偏好,进一步提升了计算效率,不过该模型主要聚焦于音乐推荐场景,通用性受到了限制。2025 年,Jiang^[111]等人提出了一种新颖的交互策略,使用不同内核大小的卷积神经网络进行特征交互,从而获得丰富的潜在特征信息,增强特征交互效果。目前,单元结构的轻量化与效率优化成为重点,例如通过优化偏置项、引入归一化内积或共享潜在特征层来显著降低交叉压缩带来的计算开销,使其更能适应大规模工业场景。另外,交叉压缩交互策略推动了性能边界,这种采用多核卷积进行深层次的特征交互,使得知识迁移不再局限于相邻实体,这些进展共同标志着交叉压缩单元从一种固定的参数共享工具,演进为一个能自适应处理多模态、高效率且富含语义的智能知识转移枢纽。

2.4.2 多任务学习辅助标签优化

辅助标签是多任务学习中通过引入额外监督信号提升模型泛化能力的关键工具,合理使用辅助标签可以在数据有限或任务复杂时显著提升模型性能。但是多任务学习预测时,当前的一些方法会假设无法访问其他任务的标签。这种假设可能会忽略了许多实际应用中的潜在有效知识。为了更好的利用辅助标签,文献^[112]提出了能够明确融合辅助任务知识的模型

MetaLink,将所有任务最后权重重新定义为任务节点,并构建了以数据点和任务为节点,相关任务的数据点标签信息为标记边的知识图谱,这样在进行多任务学习预测时,MetaLink 就可以访问其他任务的标

签从而预测给定任务的数据点标签。在生物化学和视觉领域的基准数据集上评估,实验结果其 ROC 曲线下面积提高了 27%。该文献提出的新的多任务学习环境,也就是关系多任务学习,是未来研究内容的一种新思路。另一方面,文献^[113]提出的 KGCL 模型中利用知识图谱增强模块(KG augmentation schema)来抑制 KG 噪声,同时通过跨视角对比学习范式(cross-view contrastive learning paradigm)提高推荐效果还利用知识图谱利用性能增强过程中额外监督信号,来引导非线性对比损失中的用户-项目交互,从而达到减少噪声干扰并提高推荐性能的效果。该模型通过数学矩阵分解技术实现了跨域信息融合,在处理大规模和高纬度数据也较为出色。但是由于其复杂结构,构造合适的对比样本有一定困难。目前,研究已经从人工辅助标签逐步转向标签语义关系的结构化挖掘与自动化利用。同时,自动化与自适应标签融合技术受到关注,研究重点从如何设计辅助标签转向如何让模型自动发现并量化不同任务标签间的相关性,减少对先验知识的依赖。这些技术趋势共同推动辅助标签优化从一种辅助技术,演进为构建可推理、可泛化且抗噪声的多任务学习系统的核心驱动力。

2.4.3 多任务学习跷跷板问题优化

跷跷板问题出现主要原因是多任务梯度、多任务收敛速度不一致以及数量级差异大导致的。Ma^[114]等人提出了模型 MMoE(Multi-gate Mixture-of-Experts),通过共享专家网络(shared experts)实现信息的共享,同时针对每个上层任务都有对应的门控函数,学习到多个专家对特定任务的贡献程度,从而实现任务之间的关联和区别的学习。Tang^[115]等人提出的 PLE 模型在 MMoE 的基础上通过对共享的网络结构优化,增加了 task-specific 的部分,构造了多层的网络结构。这种显示划分任务的方法能够在一定程度上缓解跷跷板现象。另外,Wang 等人^[116]提出的 GradVec 模型通过加大对梯度的矫正范围,从而调整多任务虚学习过程中的平衡性,减少不同任务之间的冲突。综上所述,目前研究已经从通用结构设计深入到对任务因果与动态关系的精准调控,尤其是专家混合结构的精细化设计成为主流,利用多层门控网络动态信息,从结构上规避了任务间的特征冲突,另外梯度操作与随时平衡算法持续演进,基于不确定性的自

适应加权技术被广泛应用，这些优化策略为构建稳定高效的多任务推荐系统提供了坚实的基础。

2.4.4 多任务学习优化总结

在多任务学习模块优化方法中，交叉压缩单元、辅助标签应用以及跷跷板现象这三方面优化，并非孤立的技术迭代，而是从不同维度对多任务学习本质挑战的协同攻关。交叉压缩单元的优化重点在于重构知识转移的路径与效率。这不仅显著降低了计算复杂度，更重要的是通过图神经网络、多核卷积等技术，实现了更深层次、更富语义的跨任务知识蒸馏。辅助标签的优化则聚焦于扩展和净化监督信号的来源。其发展轨迹是从人工引入辅助标签，转向让模型自动发现并量化不同任务标签间的语义关联。跷跷板现象的优化策略致力于协调任务间的竞争与协作关系。其思路从初期的硬参数共享，发展到如今显式分离共享参数与任务特定参数

2.5 数据集分析与介绍

本节主要介绍知识图谱推荐算法数据集（前文提到数据集不再重复）。DBP15K 数据集是知识图谱实体对齐研究领域的核心基准数据集，以其跨语言特性、结构化异构性和丰富的评估场景成为衡量实体对齐算法性能的重要标准。该数据集基于多语言

DBpedia 构建，旨在解决跨语言知识图谱融合问题。该数据集包含三个子集，每个子集包含约 15000 个跨语言实体对。但是跨语言图谱的邻居拓扑差异显著，导致嵌入空间难以对齐，且原生数据集未显示标注属性层级。

WN18 基于英语词汇数据库 WordNet 构建，为早期知识图谱嵌入模型提供了基准测试平台，解决了多关系数据的表示学习问题。但是该数据集中存在大量可逆关系对，导致模型通过简单规则即可预测，而非学习深层语义，并且也未显示标注实体层级，限制模型对语义结构的理解。对此研究者提出 WN18RR 数据集，删除了所有可逆关系，消除了规则漏洞，迫使模型学习真实语义，且进行了显式标注，促进层级感知模型的发展。

FB15k 是知识图谱表示学习与链接预测领域最具影响力的基准数据集之一。该数据集提取自 Freebase 知识库，精选高频实体与关系形成子集。但是其长尾实体关联三元组较少，且冷启动问题显著，对此研究者提出改进版被 FB15k-237，删除所有方向关系，保留 200 多种不可逆关系，促使模型学习复杂语义而非依赖规则。数据集如表 8 所示：

表 8 数据集汇总
Table 8 Dataset Summary

数据集名称	发布时间	包含数据集系列	规模与类型	优点	缺点	引用模型
DBP15K 系列	2017	DBP15K (ZH-EN)	数十万关系三元组 核心特征：典型的 跨语言异构知识图 谱	提供了高质量的 预对齐实体对作 为种子映射。 为后续研究工作 扩展了图像等多 模态信息	规模相对较小， 对于训练超大规 模模型可能显得 不足	RKDEA ^[62]
		DBP15K (JA-EN)				DistMult ^[68]
		DBP15K (FR-EN)				CompLex ^[69] TuckER ^[70]
WN18 系列	2013	WN18	从 WordNet 抽 取，包含 40,943 个实体和 18 种词 汇关系	关系多为上下位 义、部分整体等 语言学关系，适 合研究语义层级 结构	关系类型较少， 关系多样性有限	TransE ^[76]
		WN18RR				TransH ^[75] TransR ^[77]
						TranSparse ^[78] RotateE ^[81] Quate ^[83] HAKE ^[84] DistMult ^[68] CompLex ^[69]
FB15k 系列	2013	FB15k FB15k-237	从 Freebase 抽取 的子集，包含 14,951 个实体和 1,345 种关系	是当前评估模型 泛化能力的核心 基准之一	关系冗余与长尾 分布	TuckER ^[70] TransE ^[76] TransH ^[75] TransR ^[77]

TranSparse^[78]
 RotateE^[81]
 Quate^[83]
 HAKE^[84]
 PairRE^[80]
 DsMtGCN^[88]

2.6 现有方法的分类和总结

为了更好的理解和区分各个模型,本节根据应用知识图谱的不同形式,可分为三类:基于嵌入的方法、基于路径的方法和基于传播的方法。基于嵌入的方法侧重于将知识图谱中的实体和关系映射到低维向量空间,通过向量运算来捕捉语义信息并辅助推荐。基于传播的方法则通过在知识图谱上进行信息传递和

聚合,如利用图神经网络或偏好传播机制,来丰富用户和物品的表示。基于路径的方法则关注于挖掘知识图谱中连接用户和物品的路径模式,并利用这些路径信息进行推荐。每种方法都有其独特的优势和适用场景,并在不同程度上解决了传统推荐系统面临的数据稀疏性和冷启动等问题。对比表如表9所示。

表9 三种方法模型对比总结

Table 9 Comparison and Summary of Three Method Models

方法分类	推荐模型	核心框架	优化重点	模型总结
基于嵌入的方法	TransE ^[76]	矩阵分解	知识嵌入	向量平移嵌入模型
	TransH ^[75]	矩阵分解	知识嵌入	超平面上的翻译嵌入
	TransR ^[77]	矩阵分解	知识嵌入	不同关系空间中学习嵌入
	TranSparse ^[78]	矩阵分解	知识嵌入	稀疏知识图谱的翻译嵌入
	RotateE ^[81]	矩阵分解	知识嵌入	旋转操作建模关系
	DistMult ^[68]	矩阵分解	知识推理	双线性嵌入模型关系学习
	ComplEx ^[69]	矩阵分解	知识推理	复数嵌入处理对称关系
	Tucker ^[70]	矩阵分解	知识推理	Tucker 分解高阶交互
	Quate ^[83]	矩阵分解	知识嵌入	四元数嵌入的 KGE 模型
	HAKE ^[84]	矩阵分解、卷积神经网络	知识嵌入	层级感知知识嵌入
	PairRE ^[80]	矩阵分解	知识嵌入	简化关系嵌入模型
	MKR ^[107]	注意力机制、卷积神经网络	多任务学习	多任务知识嵌入学习
	IncDE ^[65]	蒸馏嵌入	知识融合	增量深度嵌入
	RKDEA ^[62]	蒸馏嵌入、卷积神经网络	知识融合	关系知识蒸馏嵌入
	MAPKR ^[108]	注意力机制	多任务学习	嵌入优化知识表示学习
基于路径的方法	TuTR ^[71]	矩阵分解	知识推理	基于张量分解的嵌入学习
	KG-RAG4SM ^[61]	卷积神经网络	知识融合	基于检索增强的路径方法
	MetaLink ^[112]	卷积神经网络	多任务学习	基于元路径或链接路径的方法
	KGIN ^[49]	卷积神经网络	信息聚合	递归集成关系路径
	ECRN ^[117]	卷积神经网络	信息聚合	路径链接挖掘潜在关系
	MG-HIF ^[118]	生成对抗网络	信息聚合	元路径生成不同顶点的序列
	IRL ^[119]	卷积神经网络	知识推理	基于元路径的路径编码器来建模
	RippleNet ^[96]	注意力机制	信息聚合	涟漪网络传播用户偏好
	HGKR ^[46]	卷积神经网络、注意力机制	知识融合	层次图知识传播
	Fusion-Mamba ^[60]	注意力机制	知识融合	基于 GNN 融合传播机制

基于传播的方法	IKEGCL ^[48]	注意力机制	知识融合	GNN 传播进行对比学习
	ML-KDGATMoco ^[47]	卷积神经网络、注意力机制	知识融合	图注意力传播。
	KGCFRec ^[50]	注意力机制	信息聚合	基于图卷积传播
	FIRE ^[92]	卷积神经网络、强化学习	信息聚合	灵活交互关系传播
	DsMitGCN ^[88]	卷积神经网络	信息聚合	双端多任务图卷积网络传播
	HMGCN ^[95]	卷积神经网络	信息聚合	多尺度传播卷积网络
	KGCN ^[97]	注意力机制、卷积神经网络	信息聚合	知识图卷积网络传播方法
	KRGAT ^[98]	卷积神经网络、注意力机制	信息聚合	知识感知关系图注意力网络
	DiffKG ^[100]	自动编码器	信息聚合	知识图扩散传播方法
	GTF-Ne ^[99]	注意力机制	信息聚合	基于自注意力传播方法
	KGCL ^[113]	卷积神经网络	信息聚合	知识图对比学习传播方法

3 大模型与知识图谱融合的推荐系统

尽管知识图谱作为辅助信息的引入为推荐系统带来了突破性的发展，但是仍然存在着以下局限：

- （1）知识覆盖不足：人工构建的知识图谱常面临事实缺失、范围有限问题，导致实体间语义连接断裂。
- （2）语义理解局限：传统方法将实体和关系转换为 ID 嵌入，丢失了文本描述的丰富语义信息。
- （3）多维度复杂场景难以适应：这类任务往往需要多轮决策与外部数据交互

大语言模型（Large Language Models, LLM）的兴起为上述问题提供了新的解决路径。LLM 凭借其强大的语义理解能力、丰富的世界知识和复杂推理能力，正深刻变革推荐系统的设计范式。但其在获取和验证事实信息方面往往存在困难。与之不同的是，知识图谱（KG）通过保存结构化的事实知识，为 LLM 提供更多的数据支持以进行解释和推理。将 LLM 与 KG 相结合，可以充分发挥两种技术的优势，从而提升性能、知识提取与丰富度、上下文推理与个性化、可靠性、可解释性以及可扩展性

3.1 关键技术的对比与演进

LLM 与知识图谱的融合推荐技术的方法归纳为三大核心范式：LLM 作为推荐模型核心优化、LLM 作为推荐系统外部知识增强器的优化、LLM 驱动的多智能体协同优化，研究发现这些集成技术在实时数据分析、高效决策支持和跨领域创新推动方面具有显著提升作用。

3.1.1 LLM 作为推荐模型核心优化

这类模型将 LLM 本身视为推荐模型框架，通过

设计特定的提示(Prompt)工程或进行轻量级微调，将推荐任务转化为 LLM 能够理解和处理的自然语言序列或结构化指令，直接利用 LLM 的生成或理解能力进行推荐预测。而为了进一步解决传统 ID 嵌入的语义鸿沟问题，以及目前仍然存在推荐结果过度依赖文本语义的问题，Hou 等人^[120]提出了一种面向可迁移序列推荐系统的创新框架 VQ-Rec，通过向量量化技术解耦项目文本与项目表示之间的强绑定关系，提升推荐模型在跨域、跨平台场景中的泛化能力。其核心是将项目文本映射为离散编码，使用优化产品量化技术保证编码分布均匀性。在 Amazon 跨域推荐中 AUC 提升 14.2%。为了进一步驱动高阶语义理解，统一语言化范式。文献^[51]提出了一种文献阅读助手 P5，能够将推荐任务统一转换为文本生成问题。并把用户行为、项目属性和评论转化为统一文本序列，再将不同的推荐任务整合到一个共享的自然语言生成框架中。而文献^[52]提出的 TALLRec 模型，使用了双阶段微调框架，将推荐任务转化为 LLM 可理解的自然语言决策问题，显著缩小了预训练任务与推荐任务的语义差距。另一方面，常识图谱融入也是一种重要方法，Luke 等人^[121]创新性地利用 LLM 挖掘物品间的互补与替代关系，构建基于常识的知识图谱。该方法弥补了元数据 KG 的局限性，通过互信息最大化将常识知识融入推荐过程。目前，研究进展主要突显出三大优化方向。首先语义统一与表征解耦成为关键，通过大量的向量量化等技术，剥离了项目文本与其表示的强绑定关系，有效缓解了 ID 嵌入的语义鸿沟问题，并且大幅度提升了模型在跨域场景的泛化能力。其次，任务统一与指令精细化能够将各类推荐任务统一化，通过设计好的

提示模板缩小预训练与推荐任务间的语义差距。另外在研究通过驱动 LLM 自动挖掘项目间隐含的互补、替代等常识关系,并构建知识图谱融入推荐流程,极大增强了模型对用户意图的高阶语义推理能力。这些趋势标志着 LLM 正从一个通用的语言处理器,演进为一个能深度理解推荐场景、兼具泛化与推理能力的核心推荐引擎。

3.1.2 LLM 作为推荐系统外部知识增强器的优化

为了解决知识图谱构建成本较高,且面临事实缺失和领域局限的问题。早期的研究尝试直接将 LLM 作为推荐器,但是推荐结果并不理想。对此 Xi 等人^[122]提出了 KAR (Knowledge Augmentation from LLMs) 框架,将 LLM 视为开放世界知识源,而非直接推荐器,通过知识增强提升传统推荐模型性能,其核心是通过因子分解提示 (Factorized Prompting) 将复杂用户偏好分解为关键因子(如“电影导演风格”或“商品材质偏好”),驱动 LLM 生成开放世界知识。生成的推理知识通过混合专家适配器转换为推荐空间可用的增强向量,显著提升了华为新闻和音乐推荐平台的点击率。实验表明,KAR 在公共数据集上 NDCG 提升达 12.7%,且与多种推荐算法兼容。类似的,Zhai 等人^[123]介绍了一种新的推荐框架 Knowledge Prompt-tuning for Sequential Recommendation (KP4SR),该方法通过引入外部知识库,利用知识提示同时使用领域内和通用知识。此外该方法利用结构化知识图谱转换为知识提示,来改善序列推荐中的语义差距问题。早期的推荐系统通常将大语言模型用于数据增强,从而忽略了在候选集过滤阶段的推理能力,对此 Chen 等人^[55]提出的 CORONA (Chain Of Retrieval ON grAphs) 框架首次将 LLM 嵌入图推荐的候选过滤阶段,并设计了三级渐进检索机制,在偏好辅助检索中,基于用户画像的 LLM 推理生成查询向量,从交互图中提取泛化偏好子图;在意图辅助检索中,结合历史行为与子图统计信息,LLM 执行意图推理压缩子图;在图增强检索中,GNN 捕捉子图的高阶协同过滤信号生成最终推荐。并且在 Netflix 和 MovieLens 上的实验表明,CORONA 召回率平均提升 18.6%,且在物品冷启动场景下 NDCG 提升 10.68%。另外,融合 LLM 进行推荐还存

在着幻觉问题 (Hallucination Problem),即 LLM 生成与事实不符、逻辑错误或缺乏依据内容,对此,Yang 等人^[124]提出了 CP-KGC 框架,通过设计约束提示,将实体极其原始描述作为上下文输入,引导 LLM 生成更精准的文本。并且还使用 BERT 模型计算生成同义词与实体的相似度,设定阈值过滤低信用结果。总体来说,LLM 与图模型的深度协同成为突破点,新兴框架将 LLM 嵌入图推荐的候选生成与过滤阶段,通过多级渐进式检索机制,让 LLM 负责意图推理与查询构造,图模型负责捕捉高阶协同信号,实现了生成式语义与图结构语义的优势互补。此外,幻觉抑制与知识可信保障成为必要环节,研究通过约束提示、上下文注入及相似度阈值过滤等技术,有效减少了 LLM 生成知识中的事实性错误,确保了增强知识的可靠性与可用性。这些进展共同推动了 LLM 从“辅助工具”升级为推荐系统中一个可靠、高效的外部知识大脑。

3.1.3 LLM 驱动的多智能体协同优化

智能体系统能将复杂目标拆解为若干子任务,分步进行系统化处理。这种机制突破了纯文本查询的局限,通过构建更稳健、情境感知更强的决策流程,更贴近人类思维模式^[53]。此外,通过将认知负荷分散到不同组件,智能体框架还能有效降低“幻觉”或答案不完整风险,确保最终结果不会单纯依赖单次预测^[54]。但是由于领域自适应以及系统验证的要求,直接将这种框架应用到知识图谱增强仍具有挑战性。对此,LU 等人^[125]提出了一个新的多智能体协作架构 KARMA,能够部署多个智能体分阶段协作处理知识图谱增强任务。该框架采用的领域自适应提示能够指导智能体工作,并建立交叉验证闭环,即关系抽取与模式对齐智能体相互校验,有效减少幻觉 18.6%,在 PubMed 文献图谱构建中实现了高精度的自动实体新增 38,230 个。与 KARMA 框架不同,Gao 等人^[126]提出的 Graph Counselor 框架采用了三智能体分工,并添加了双层反射架构。即内层推理循环和外层反思结构。相较于 KARMA 类似流水线的知识提取路径,Graph Counselor 更能够动态调整推理路径,并进行自我反思调节。这两种框架中,前者可以处于上游辅助构建高质量知识图谱,后者可以处于下游利用图谱进行复杂推理。为了进一步提高系统性能,Rasmussen 等人^[127]将融合时序知识图谱与智能体记忆模块融合,提出了一个具备时间感知的知识图谱引擎,能动态整合非结构化对话数据和结构化业务数据,同时保持历史关联。实验结果中,准确率较基线方案提高高达 18.5%,响应延迟则减少 90%。总体来说,分工与验证机制的设

计是核心创新,如 KARMA 框架通过部署关系抽取、模式对齐等专业智能体,并建立交叉验证闭环,显著提升了知识图谱增强任务的精度与可靠性,有效控制了幻觉现象。其次,动态推理与反思能力得到增强,不同于固定流水线,,使智能体系统能够动态调整推理路径,进行自我质疑与修正,从而应对更复杂的场景。第三,时序感知与记忆融合成为新焦点,研究将智能体与时序知识图谱引擎结合,使其能够整合历史对话与实时业务数据,在动态变化的环境中保持决策的连贯性与准确性。这些趋势表明,LLM 驱动的多智

能体系统正从一个概念验证,发展为一个能够执行高精度、高可信度知识工作的自动化认知团队。

3.2 现有方法的分类和总结

本节从 LLM 作为推荐模型核心优化、LLM 作为推荐系统外部知识增强器的优化和 LLM 驱动的多智能体协同优化三个方法总结了各个模型的核心思想、数据集、实验结果和基线模型,如表 10 所示:

表 10 现有方法的分类和总结

Table 10 Comparison and Summary of Three Method Models

使用方法	模型名称	发表时间	核心思想	数据集	实验结果	基线模型对比	优点	缺点
LLM 作为推荐模型	P5 ^[51]	2022	统一多任务建模	Amazon-Sports	HR@10: +7%	SASRec	在多个推荐任务上实现了协同优化,在资源消耗与性能之间取得了较好平衡	需进一步引入约束机制或后处理策略以提升生成质量
	VQ-Rec ^[114]	2023	向量化学习离散项目	Amazon 数据集	NDCG@10: +7.5%, Recall@10: +4.2%	SASRec	缓解了直接使用 PLM 文本编码导致的“过度依赖文本特征”和“跨领域语义差异干扰”问题	性能高度依赖项目文本的质量和丰富度
	TALLRec ^[52]	2023	对齐 LLM 与推荐任务	Amazon-book、MovieLens、Netflix	NDCG@20: +5.3%, Recall@20: +6.5%	LightGCN, GRCN	通过指数移动平均动态调整梯度目标显著提升模型性能	对极低资源任务的提升相对有限
LLM 作为外部知识增强器	KAR ^[122]	2023	大语言模型提取开放世界知识	Movielens-1M、Amazon-Books、MovieLens-1M、	NDCG@7: +4.71%,AUC: +1.24 (MovieLens), +1.38% (Amazon)	P5,DLC M	创新性融合 LLM 与多模块对话推荐架构	LLM 生成内容可能存在事实性错误或偏离推荐目标
	KP4SR ^[123]	2023	关系模板转化知识提示	Amazon-Books、LFM-1b (music)	NDCG@5: +40.65% (books), +11.17% (music), +22.17% (movies)	P5,SAS Rec	将结构化知识图谱转化为文本形式,显著提升了顺序推荐的准确性	过多跳数的知识提示可能引入噪声
	LLMRec ^[53]	2024	利用 LLM 增强交互图	Amazon-book、MovieLens、Netflix	NDCG@20: +5.8%, Recall@20: +7.2%	LightGCN, NGCF	引入上下文约束机制,显著降低多义实体带来的噪声干扰	过度语义扩展可能引入噪声

LLM 驱动的多智能体协同	LLM-In ^[54]	2024	LLM 模拟用户交互行为	Amazon-book、MovieLens、Netflix	NDCG@20: +9.1%, Recall@20: +12.3%	Dropout Net	支持根据任务复杂度自适应调整迭代次数, 避免“推理不足”或“过度推理	多轮迭代与反思机制导致单次推理计算量大
	CORONA ^[55]	2025	结合 LLM 三阶段检索	Amazon-book、MovieLens、Netflix	NDCG@20: +18.4%, Recall@20: +18.6%	LightGC N	支持多种 GNN 架构, 在保持性能的同时具备灵活的部署选项。	在极端稀疏数据下, 性能增益有限
	Graph Counselor ^[126]	2024	增强 LLM 推理能力	GRBEN CH, Web QSP	Rouge-L: +16.14%, QwenScore: +13.96%	GraphR AG, Base LLMs	支持图操作的并行与串行组合, 提升了信息提取的粒度与完整性	时间成本可能限制其在实时场景中的应用
	Zep ^[127]	2024	基于时间感知知识图引擎	DMR, longMemEval	准确率: +4.0%	MemGPT	将长文本结构化表示为图, 节点捕获关键元素与原子事实	高度依赖底层的规划与推理能力
LLM 驱动的多智能体协同	KARMA ^[125]	2025	多智能 LLM 处理 KG 补全	1,200 篇 PubMed 文献	RLC 正确性评分: +8%	单智能体模型	低耦合设计支持灵活添加新功能模块或更新提示模板, 适应不断演进的知识体系。	LLM 训练数据中的历史偏见可能被引入知识图谱

4 基于知识图谱推荐领域应用

随着人工智能技术的迅猛发展, 尤其是知识图谱与推荐系统的深度融合, 其应用领域已从早期的电影、音乐、新闻等娱乐和资讯推荐逐渐向医学和电商等更具专业性和商业价值的领域拓展。这种转变的必然性源于两方面: 一方面, 传统推荐场景的数据结构和用户需求相对简单, 知识图谱的引入虽能提升个性化效果, 但其技术潜力在复杂领域更能得到充分发挥; 另一方面, 医学领域需要整合多源异构数据(如电子病历、医学文献和基因组学信息)以实现精准诊疗推荐, 而电商领域则依赖商品属性、用户行为和供应链知识的深度关联来优化消费体验, 这些需求恰恰与知识图谱强大的语义推理和关系建模能力高度契合。对此本章从医学领域和电商领域进行介绍。

4.1 医学领域

在医学领域, 推荐系统利用知识图谱构建疾病-症状关系模型, 可以用于辅助问诊和推荐相关的处方。目前基于知识图谱的推荐系统已经被应用于药物推荐、疾病诊断、个性化体检等领域^[128]。但是医学领域的推

荐不同于其他领域, 用户面临着推荐安全性和用药安全性。因此对于推荐系统的数据质量、算法可靠性、安全性要求十分严苛。文献^[129]首次结合 EMR(患者诊疗记录)与医学知识图谱, 弥补了传统推荐系统只依赖 EMR 的局限性。并通过统一嵌入空间捕捉跨实体语义关联。与传统医疗推荐模型相比, 信息更加完整, 该模型能联合嵌入学习支持多疾病联合用药推荐。并基于知识图谱的链路预测提供部分可解释性。但其模型性能受知识图谱的质量影响。对此, 文献^[130]提出了名为 Safe Medicine Recommendation (SMR) 的新框架, 将电子病历与医疗知识图谱相链接, 构建了高质量的异构图, 并将患者症状、疾病、药物间关系嵌入到低维空间, 从而分解药物推荐问题, 并考虑患者的诊断和不良药物反应。在过去的研究中, 由于多药物联合使用的非线性效应, 以及个体化的差异, 传统模型对于各类药物的不良反应预测需要构建独立的模型, 文献^[131]设计了一种药物不良反应预测模型, 能够融合不同药物间的关联信息, 也能够对实验覆盖中不良反应进行统一的预测, 提升了用药的安全性和精确性。为了进一步降低药物不良反应的发生率, 文献^[132]利用

双向 LSTM 和注意力机制的关系抽取模型构建了知识图谱规则库,并在此基础上建立了用药检测系统。相似的,目前许多研究利用多源异构医疗大数据来构建用药风险框架,用以检测处方中的用药风险。除了用药的安全性,传统医学推荐算法往往会忽略药品自身语义信息,从而导致推荐精度较低,文献^[133]提出了一种融合协同过滤和知识图谱的 TransR-CR 的推荐算法,通过计算药品间语义相似度,并将其与行为相似度融合进行推荐,提高了准确率以及可信度。文献^[134]提出了一种因果推理模型,该模型首先通过将患者的症状与图谱中疾病节点匹配,计算出患者与疾病的共现概率,再利用动态阈值输出疾病诊断结果,同时将分析得到的症状与图谱中疾病的关系反馈给医生用以辅助诊疗,从而提高诊疗效率。除此之外,医疗数据涉及敏感个人信息,如何在保障隐私的前提下实现数据共享和融合也是一个重要难题,尤其是利用知识图谱实体关联可能会暴露患者身份隐私,而传统的差分隐私(DP)机制(如 RippleNet+DP)虽然能够降低风险^[135],但是会牺牲推荐精度。文献^[136]针对此问题采用同态加与哈希函数构建了 H2E 模型,并设计了可解释的隐私-效用权衡机制,能够在分散的方式进行推荐计算,在不牺牲准确率和效率的同时,保护用户隐私。

4.2 电商平台领域

目前电商平台用户兴趣会随时间快速变化,具有很强的时效性,而时序图卷积网络虽然能建模动态兴趣,但是对于大规模的图谱迭代计算效率偏低,用户隐式反馈的噪声也会进一步影响动态建模的鲁棒性。主要从抖音、淘宝、拼多多三大典型电商平台分析介绍,抖音作为短视频平台,其主要推荐的推荐数据是用户行为,例如观看时长、点赞、评论等,而这些行为具有娱乐性、时效性和数量庞大的特点,因此抖音平台更需要构建知识图谱来捕捉用户兴趣的多样性和动态变化,以实现精准推荐。而抖音的兴趣点推荐需要将短视频内容与地理位置用户行为等进行路径结合,这种多模态间的异构性和语义鸿沟增加了融合难度。对此,其推荐系统以高效的信息提取和个性化内容推荐为核心,采用了分层召回策略,通过内容属性(如类型、流行度和主题)定位用户兴趣,而并不是基于用户历史记录推荐^[137],另外通过微服务架构实现了高并发和高可用性,并利用自适应降级和熔断组件等技术保障系统的稳定性,同时抖音还引入了兴趣点推荐系统,结合用户行为数据和地理位置信息,进一步丰

富内容。而淘宝平台主要集中在购物行为,数据稀疏性较高,尤其是冷启动问题,同时还存在信息损失和计算冗余。淘宝的推荐系统架构包括用户-候选匹配、实时预测和排名策略三个模块^[138],主要注重实时性和准确性,此外淘宝还采用了基于深度学习的模型如(GRU4REC)来提升性能,并结合上下文感知重新排序技术,以提高点击率和交易转换率。拼多多则是通过社交信任机制和用户画像来增强推荐效果,该算法设计结合了用户行为数据和社交网络数据,使用多层神经网络系统优化商品推荐。

4.3 大模型应用领域

近年来,大模型与知识图谱的耦合从外挂知识库逐渐演变为图谱即参数的新模式,以 GraphRAG^[139]为代表,在 LLM 进行文本生成时,GraphRAG 可以将知识图谱中信息作为参考。另一方面,GraphRAG 利用图神经网络来对文本中的语义关系进行建模,有助于 LLM 生成更加符合语义和逻辑的文本内容。并且能将十亿级实体-关系图压缩为层级索引,在毫秒级延迟内完成跨文档摘要,已被微软 Bing 新闻推荐采纳,用于解决多跳推理和冷启动场景下的可解释排序问题。LightRAG^[140]则是将 GraphRAG 的思想轻量化,将用户请求划分为四级复杂度,LightRAG 的成功标志着 LLM-KG 系统从单一问答向复杂决策支持的演进。蚂蚁集团^[141]提出的 LLM-KERec 系统(Large Language Model with Knowledge Enhanced Recommendation)开创了互补知识图谱范式。其核心创新在于构建实体-实体-物品互补图(Entity-Entity-Item Complementary Graph)利用 Claude-2 驱动实体互补关系推理,构建“实体-实体-商品”权重图,通过双塔 GNN 在线决策,在支付宝 3 个场景的 A/B 测试中带来 6.24%~10.07% 的转化率提升。通过 LLM 推理实体间潜在互补关系,该系统还设计了增量更新机制,通过每日调度更新图谱结构,解决了电商场景实体热度动态演变的挑战^[142]另外,更大参数规模的 DeepSeek-Rec^[143]依托 67B-MoE 模型,在预训练阶段注入千亿级商品 KG 三元组,通过专家路由将关系类型映射到不同专家子网络,实现毫秒级个性化重排,已在短视频与跨境电商搜索中全面替换原双塔模型。总体来看,GraphRAG 提供可解释链路,LightRAG 优化延迟,LLM-KERec 与 DeepSeek-Rec 分别从互补推理和超大规模语义对齐切入,共同标志着推荐系统进入“图谱增强的百亿参数”时代。

5 现存挑战及未来展望

基于知识图谱的推荐系统仍面临诸多技术瓶颈和开放性挑战。本章从知识图谱模块优化、推荐任务模块优化以及多任务优化三个维度,系统梳理当前研究的核心问题,并结合最新研究趋势提出未来发展方向。

5.1 知识图谱模块优化方面

(1) 动态知识更新与时效性不足: 现有知识图谱多依赖静态数据构建,难以适应实时变化的用户兴趣。尽管 TKG 研究取得进展,但动态实体关系的高效更新仍受限于计算复杂度,例如 TUTR 模型虽支持四维张量建模,但万级节点实时更新的训练时间仍呈指数增长。

(2) 长尾实体与稀疏性问题: 冷门领域(如罕见病诊疗)的实体覆盖率低,现有嵌入方法对长尾实体表征能力不足,导致链接预测准确率大幅下降

未来发展趋势主要是结合增量学习和边缘计算,实现局部图谱的实时更新,同时深度探索时序扩散模型补全动态关系。

5.2 推荐任务模块优化方面

(1) 高阶关系建模的复杂度与可解释性矛盾: 现有模型在通过多跳聚合捕捉高阶语义时,计算量会随跳数增加呈指数性增长,且路径可解释性也会下降。另外,注意力机制虽能动态分配权重,但多头注意力的正交约束可能过度简化意图独立性假设。

(2) 多源异构数据融合困难: 用户行为数据、社交网络、知识图谱等多模态数据的对齐与融合需要更好的统一框架,且在跨领域知识迁移时,实体语义歧义性会加剧。

未来可以引入因果图模型,区分混淆因子,减少数据偏差导致的“信息茧房”效应。另外还需要加强同态加密与知识蒸馏在推荐系统上的应用,使得在分布式环境下能够实现隐私安全的跨域推荐。

5.3 多任务模块优化方面

(1) 任务冲突与负迁移: 推荐与知识图谱补全的目标函数可能存在梯度冲突,需要提升交叉压缩单元部分的模型性能

(2) 计算效率瓶颈: 多任务联合训练需同步优化异构损失函数,避免参数量过度增长影响模型计算效率。

(3) 辅助标签利用不足: 当前方法虽能融合跨任务标签,但未考虑标签噪声,可能误导模型训练。

未来发展的方向主要是增强动态任务路由机制,通过门控函数动态分配任务计算资源,缓解冲突。同时进行稀疏化联合训练:对部分任务采用模块化设计,实施分阶段稀疏训练,降低计算开销。另外增强自监督任务,构建对抗性负采样策略,利用对比学习生成高质量辅助标签,减少噪声干扰。

5.4 大模型结合优化方面

(1) 维护准确且与时俱进的知识图谱: 知识动态变化的特性要求持续更新知识图谱。维护准确且与时俱进的知识图谱是一项复杂任务,需要自动提取、验证和整合新信息,同时解决信息不一致和重复问题。对于依赖知识图谱进行精准推理和情境响应的语言模型而言,知识图谱更新的滞后会直接影响生成内容的相关性和准确性。

(2) 计算资源: 使用集成了知识图谱 LLM 进行预训练和微调需要消耗大量计算资源,通常需要高性能 GPU 或 TPU 以及大容量内存。集成过程包括在海量文本语料库上训练 LLM,并对复杂图结构进行编码和嵌入,这进一步增加了计算需求。这种计算开销可能限制此类集成在资源受限环境或实时应用中的可行性。

(3) 数据依赖与适应性挑战: 使用知识图谱微调再最新的领域特定知识图谱往往颇具挑战性,当在快速发展的领域中,LLM 必须迅速适应新概念和关系。若缺乏持续获取和整合新数据的方法,集成系统的性能大幅度下降,导致知识库内容缺失时效性。

(4) 事实核查与验证复杂度: 通过知识图谱验证输出结果具有一定难度。事实核查需要将生成文本与知识图谱中的实体及关系进行映射,这不仅计算成本高昂,也相当耗时。此外,核查过程仍可能遗漏特定细节或情境相关的不准确信息,使得难以确保输出完全可靠。

6 结束语

知识图谱凭借其强大的语义关联与结构化知识表示能力,已成为突破传统推荐算法瓶颈的关键赋能技术。本综述系统性地剖析了知识图谱与推荐算法融合的研究脉络与最新进展,创新性地提出模块化解耦框架,将融合过程分解为三大核心维度,并围绕各维度的发展历程、优化策略、核心技术进行了深度梳理与对比分析。研究进一步揭示,LLM 的兴起正深刻重塑

融合范式,涌现出 LLM 作为推荐核心、外部知识增强器及多智能体协同驱动等创新路径。在应用层面,知识图谱推荐技术在医学、电商、大模型等关键领域展现出巨大价值。尽管研究已取得显著成果,融合系统仍面临动态知识更新时效性不足、多源异构数据对齐

困难、和计算效率瓶颈。未来研究需持续探索增量学习与边缘计算驱动的动态图谱更新、因果图模型引导的偏差修正,推动推荐系统在保障用户隐私与效能的平衡的方向发展。

参考文献:

- [1]. ZHANG L, BI W, ZHANG N, et al. Coping with homogeneous information flow in recommender systems: algorithmic resistance and avoidance[J]. International Journal of Human-Computer Interaction, 2024, 40(22): 6899-6912.
- [2]. ZHANG J C, ZAIN A M, ZHOU K Q, et al. A review of recommender systems based on knowledge graph embedding[J]. Expert Systems with Applications, 2024: 123876.
- [3]. LIU Y, XU Y, LIU Z. Knowledge Graph: A Recommendation Method for New Media Short Videos[J]. Advances in Education, Humanities and Social Science Research, 2024, 12(1): 87-87.
- [4]. GE X, WANG Y C, WANG B, et al. Knowledge graph embedding: An overview[J]. APSIPA Transactions on Signal and Information Processing, 2024, 13(1).
- [5]. LIANG W, MEO P D, TANG Y, et al. A survey of multi-modal knowledge graphs: Technologies and trends[J]. ACM Computing Surveys, 2024, 56(11): 1-41.
- [6]. 崔明宇. 基于自然语言处理的基础教育知识图谱的构建[D]. 山东:青岛理工大学,2023.
- CUI M Y. The Construction of knowledge graph in basic education field based on natural language processing[D]. Qingdao University of Technology, 2023.
- [7]. ROY D, DUTTA M. A systematic review and research perspective on recommender systems[J]. Journal of Big Data, 2022, 9(1): 59.
- [8]. ZHANG W, BEI Y, YANG L, et al. Cold-Start Recommendation towards the Era of Large Language Models (LLMs): A Comprehensive Survey and Roadmap[J]. arXiv preprint arXiv:2501.01945, 2025.
- [9]. ABDULLAH N A, RASHEED R A, NASIR M H N M, et al. Eliciting auxiliary information for cold start user recommendation: A survey[J]. Applied Sciences, 2021, 11(20): 9608.
- [10]. VOGT L, KUHN T, HOEHNDORF R. Semantic units: organizing knowledge graphs into semantically meaningful units of representation[J]. Journal of biomedical semantics, 2024, 15(1): 7.
- [11]. XU S, JI J, LI Y, et al. Causal Inference for Recommendation: Foundations, Methods, and Applications[J]. ACM Transactions on Intelligent Systems and Technology, 2025, 16(3): 1-51.
- [12]. 王国霞,刘贺平. 个性化推荐系统综述[J]. 计算机工程与应用,2012,48(7):66-76.
- WANG G X,LIU H P.Survey of personalized recommendation system[J].Computer Engineering and Applications,2012,48(7):66-76.
- [13]. 刘建国,周涛,汪秉宏. 个性化推荐系统的研究进展[J]. 自然科学进展,2009,19(1):1-15. DOI:10.3321/j.issn:1002-008X.2009.01.001.
- LIU J G,ZHOU T,WANG B H. The research progress of personalized recommendation systems[J].Progress in Natural Science,2009,19(1):1-15. DOI:10.3321/j.issn:1002-008X.2009.01.001.
- [14]. SAAT N I Y, NOAH S A M, MOHD M. Towards serendipity for content-based recommender systems[J]. International Journal on Advanced Science, Engineering and Information Technology, 2018, 8(4-2): 1762-1769.
- [15]. VAN DAT N, VAN TOAN P, THANH T M. Solving distribution problems in content-based recommendation system with gaussian mixture model[J]. Applied Intelligence, 2022, 52(2): 1602-1614.
- [16]. 朱文奇. 推荐系统用户相似度计算方法研究[D]. 重庆:重庆大学,2014.
- ZHU W Q. Research on user similarity function of recommender systems[D]. Chongqing University, 2014.

- [17]. 李川. 实时个性化推荐系统的设计与实现[D]. 北京:北京邮电大学,2015.
- LI C.Design and implementation of real-time personalized recommendation system[D].beijing university of posts and telecommunications, 2015.
- [18]. HUANG R. Improved content recommendation algorithm integrating semantic information[J]. Journal of Big Data, 2023, 10(1): 84.
- [19]. HE L, LONG Y. Research and Implementation of Content Recommendation Algorithm Optimization Based on Multi-Source Information Fusion[J]. Academic Journal of Mathematical Sciences, 2024, 5(2): 18-24.
- [20]. FANG W, SHA Y, QI M. Movie Recommendation Algorithm Based on Ensemble Learning[J]. Intelligent automation & soft computing, 2022, 34(1).
- [21]. ZHANG C, SUN Y, CHEN J, et al. SPAR: Personalized Content-Based Recommendation via Long Engagement Attention[J]. arXiv preprint arXiv:2402.10555, 2024.
- [22]. 郁雪. 基于协同过滤技术的推荐方法研究[D]. 天津:天津大学,2009. DOI:10.7666/d.Y1677576.
- YU X.Research on recommendation methods based on collaborative filtering techniques[D]Tianjin University,2009. DOI:10.7666/d.Y1677576
- [23]. 郭艳红. 推荐系统的协同过滤算法与应用研究[D]. 辽宁:大连理工大学,2008. DOI:10.7666/d.y1419326.
- GUO Y H.On collaborative filtering algorithm and applications of recommender systems[D].Dalian University of Technology,2008. DOI:10.7666/d.y1419326.
- [24]. 荣辉桂,火生旭,胡春华,等.基于用户相似度的协同过滤推荐算法[J].通信学报,2014,35(02):16-24.
- RONG H G,HONG S X,HU C H,et al.Collaborative filtering recommendation algorithm based on user similarity[J].Journal on Communications,2014,35(02):16-24.
- [25]. RENDLE S. Factorization machines[C]//2010 IEEE International conference on data mining. IEEE, 2010: 995-1000.
- [26]. HE X, CHUA T S. Neural factorization machines for sparse predictive analytics[C]//Proceedings of the 40th International ACM SIGIR conference on Research and Development in Information Retrieval. 2017: 355-364.
- [27]. XIAO J, YE H, HE X, et al. Attentional factorization machines: Learning the weight of feature interactions via attention networks[J]. arXiv preprint arXiv:1708.04617, 2017.
- [28]. SARWAR B, KARYPIS G, KONSTAN J, et al. Item-based collaborative filtering recommendation algorithms[C]//Proceedings of the 10th international conference on World Wide Web. 2001: 285-295.
- [29]. HAITAO C, SHANSHAN S, TONGQIANG L. Improved user based collaborative filtering recommendation algorithm[J]. Inf. Stud. Theory Appl., 2015, 38(9): 100-103.
- [30]. 张瑶, 陈维斌, 傅顺开. 协同过滤推荐研究综述[J]. 微型机与应用, 2013, 32(6): 4-6.
- ZHANG Y, CHEN W B, FU S K. A Review of collaborative filtering recommendation research[J].MICROCOMPUTER ITS APPLICATIONS,2013, 32(6): 4-6.
- [31]. LIU H, HU Z, MIAN A, et al. A new user similarity model to improve the accuracy of collaborative filtering[J]. Knowledge-based systems, 2014, 56: 156-166.
- [32]. LARA-CABRERA R, GONZÁLEZ-PRIETO Á, ORTEGA F. Deep matrix factorization approach for collaborative filtering recommender systems[J]. Applied Sciences, 2020, 10(14): 4926.
- [33]. LAI P L, CHEN C Y, LO L W, et al. Coldgan: Resolving cold start user recommendation by using generative adversarial networks[J]. arXiv preprint arXiv:2011.12566, 2020.
- [34]. DURICIC T, LACIC E, KOWALD D, et al. Trust-based collaborative filtering: Tackling the cold start problem using regular equivalence[C]//Proceedings of the 12th ACM conference on recommender systems. 2018: 446-450.
- [35]. WEI J, HE J, CHEN K, et al. Collaborative filtering and deep learning based recommendation system for cold start items[J]. Expert systems with applications, 2017, 69: 29-39.

- [36]. ZHENG L, LU C T, JIANG F, et al. Spectral collaborative filtering[C]//Proceedings of the 12th ACM conference on recommender systems. 2018: 311-319.
- [37]. XU Y, ZHU L, CHENG Z, et al. Multi-feature discrete collaborative filtering for fast cold-start recommendation[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(01): 270-278.
- [38]. MENG Y, YAN X, LIU W, et al. Wasserstein collaborative filtering for item cold-start recommendation[C]//Proceedings of the 28th ACM Conference on user modeling, adaptation and personalization. 2020: 318-322.
- [39]. 张宜浩, 朱小飞, 徐传运, 等. 基于用户评论的深度情感分析和多视图协同融合的混合推荐方法[J]. 计算机学报, 2019, 42(6): 1316-1333.
- ZHANG Y H, ZHU X F, XU C Y, et al. Hybrid recommendation approach based on deep sentiment analysis of user reviews and multi-view collaborative fusion[J]. Chinese Journal of Computers, 2019, 42(6): 1316-1333.
- [40]. 崔春生, 魏盟, 车利斌, 等. 基于概率语言术语集的非个性化推荐算法研究[J]. 系统科学与数学, 2023, 43(11): 2990-3010. DOI:10.12341/jssms22833.
- CUI C S, WEI M, CHE L B, et al. Research on the non-personalized recommendation algorithm based on probabilistic linguistic term sets[J]. Journal of Systems Science and Mathematical Sciences, 2023, 43(11): 2990-3010. DOI:10.12341/jssms22833.
- [41]. WANG X, HYNDMAN R J, LI F, et al. Forecast combinations: An over 50-year review[J]. International Journal of Forecasting, 2023, 39(4): 1518-1547.
- [42]. ZHOU X. Design of a hybrid recommendation algorithm based on multi-objective collaborative filtering for massive cloud data[J]. International Journal of Advanced Computer Science and Applications, 2023, 14(2).
- [43]. HE X, DENG K, WANG X, et al. Lightgcn: Simplifying and powering graph convolution network for recommendation[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 639-648.
- [44]. HO T L, LE A C, VU D H. Multiview fusion using transformer model for recommender systems: integrating the utility matrix and textual sources[J]. Applied Sciences, 2023, 13(10): 6324.
- [45]. JIANG L, LIU L, YAO J, et al. A hybrid recommendation model in social media based on deep emotion analysis and multi-source view fusion[J]. Journal of Cloud Computing, 2020, 9: 1-16.
- [46]. LIU T, SHEN H, CHANG L, et al. Iterative heterogeneous graph learning for knowledge graph-based recommendation[J]. Scientific Reports, 2023, 13(1): 6987.
- [47]. RONG Z, YUAN L, YANG L, Yang L. Enhanced knowledge graph recommendation algorithm based on multi-level contrastive learning[J]. Scientific Reports, 2024, 14(1): 23051.
- [48]. JIANG L, YAN G, LUO H, et al. Improved Collaborative Recommendation Model: Integrating Knowledge Embedding and Graph Contrastive Learning[J]. Electronics, 2023, 12(20): 4238.
- [49]. WANG X, HUANG T, WANG D, et al. Learning intents behind interactions with knowledge graph for recommendation[C]//Proceedings of the web conference 2021. 2021: 878-887.
- [50]. PENG J, GONG J, ZHOU C, et al. KGCFRec: Improving Collaborative Filtering Recommendation with Knowledge Graph[J]. Electronics, 2024, 13(10): 1927.
- [51]. GENG S, LIU S, FU Z, et al. Recommendation as language processing (rlp): A unified pretrain, personalized prompt & predict paradigm (p5)[C]//Proceedings of the 16th ACM conference on recommender systems. 2022: 299-315.
- [52]. BAO K, ZHANG J, ZHANG Y, B et al. Tallrec: An effective and efficient tuning framework to align large language model with recommendation[C]//Proceedings of the 17th ACM conference on recommender systems. 2023: 1007-1014.
- [53]. PRASAD A, KOLLER A, HARTMANN M, et al. Adapt: As-needed decomposition and planning with language models[J]. arXiv preprint arXiv:2311.05772, 2023.
- [54]. LI S, HE Y, GUO H, et al. Graphreader: Building graph-based agent to enhance long-context abilities of large language

- models[J]. arXiv preprint arXiv:2406.14550, 2024.
- [55]. CHEN J, YANG X, YANG C, et al. CORONA: A Coarse-to-Fine Framework for Graph-based Recommendation with Large Language Models[C]//Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2025: 2048-2058.
- [56]. YANG Y. Diversified teaching of English translation courses in colleges and universities based on the integration of multiple features[J]. Appl Math Nonlinear Sci, 2024, 9(1).
- [57]. SARASWATHY P, THANGARAJ M. OBIRS: Ontology Based Intelligent Recommender System for relevant literature selection[J]. J Mech Continua Math Sci, 2020.
- [58]. ZHOU D, ZHOU B, ZHENG Z, et al. Enhancing knowledge graph generation with ontology reshaping—Bosch case[C]//European Semantic Web Conference. Cham: Springer International Publishing, 2022: 299-302.
- [59]. WANG D, TANG K, ZENG J, et al. MM-transformer: a transformer-based knowledge graph link prediction model that fuses multimodal features[J]. Symmetry, 2024, 16(8): 961.
- [60]. DONG W, ZHU H, LIN S, et al. Fusion-mamba for cross-modality object detection[J]. arXiv preprint arXiv:2404.09146, 2024.
- [61]. MA C, CHAKRABARTI S, KHAN A, et al. Knowledge Graph-based Retrieval-Augmented Generation for Schema Matching[J]. arXiv preprint arXiv:2501.08686, 2025.
- [62]. LI X, ZHANG Y, XING C. Jointly learning knowledge embedding and neighborhood consensus with relational knowledge distillation for entity alignment[J]. arXiv preprint arXiv:2201.11249, 2022.
- [63]. WANG S, WANG C, GAO J, et al. Feature Alignment-Based Knowledge Distillation for Efficient Compression of Large Language Models[J]. arXiv preprint arXiv:2412.19449, 2024.
- [64]. 黄震华, 杨顺志, 林威, 等. 知识蒸馏研究综述[J]. 计算机学报, 2022, 45(3): 624-653.
- HUANG Z H, YANG S Z, LIN W, et al. Knowledge distillation: a survey[J]. Chinese Journal of Computers, 2022, 45(3): 624-653.
- [65]. LIU J, KE W, WANG P, et al. Towards continual knowledge graph embedding via incremental distillation[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(8): 8759-8768.
- [66]. 刘娟, 段友祥, 陆誉翥, 等. 引入知识增强和对比学习的知识图谱补全[J]. 计算机工程, 2024, 50(7): 112-122. DOI:10.19678/j.issn.1000-3428.0068020.
- LIU J, DUAN Y X, LU Y W, et al. Knowledge graph completion with knowledge enhancement and contrastive learning[J]. Computer Engineering, 2024, 50(7): 112-122. DOI:10.19678/j.issn.1000-3428.0068020.
- [67]. NICKEL M, TRESP V, KRIEDEL H P. A three-way model for collective learning on multi-relational data[C]//Icml. 2011, 11(10.5555): 3104482-3104584.
- [68]. YANG B, YIH W, HE X, et al. Embedding entities and relations for learning and inference in knowledge bases[J]. arXiv preprint arXiv:1412.6575, 2014.
- [69]. TROUILLON T, WELBL J, RIEDEL S, et al. Complex embeddings for simple link prediction[C]//International conference on machine learning. PMLR, 2016: 2071-2080.
- [70]. BALAŽEVIĆ I, ALLEN C, HOSPEDALES T M. Tucker: Tensor factorization for knowledge graph completion[J]. arXiv preprint arXiv:1901.09590, 2019.
- [71]. YUE L, REN Y, ZENG Y, et al. Two-layer Tensor Decomposition for Temporal Knowledge Graph Completion[J]. Expert Systems with Applications, 2025: 127953.
- [72]. LIU R, WANG X, XIE S, et al. FL-Evo: Jointly modeling fact and logic evolution patterns for temporal knowledge graph reasoning[J]. Expert Systems with Applications, 2025, 286: 128081.
- [73]. SHEN X, ZHANG Y. A knowledge graph recommendation approach incorporating contrastive and relationship learning[J]. IEEE Access, 2023, 11: 99628-99637. Zhang Q, Wang R, Yang J, et al. Knowledge graph embedding by reflection transformation[J]. Knowledge-based systems, 2022, 238: 107861.

- [74]. YAO Y, ZHANG Z, XU Y, et al. Data augmentation for few-shot knowledge graph completion from hierarchical perspective[C]//Proceedings of the 29th International Conference on Computational Linguistics. 2022: 2494-2503.
- [75]. WANG Z, ZHANG J, FENG J, et al. Knowledge graph embedding by translating on hyperplanes[C]//Proceedings of the AAAI conference on artificial intelligence. 2014, 28(1).
- [76]. BORDES A, USUNIER N, GARCIA-DURAN A, et al. Translating embeddings for modeling multi-relational data[J]. Advances in neural information processing systems, 2013, 26.
- [77]. LIN Y, LIU Z, SUN M, et al. Learning entity and relation embeddings for knowledge graph completion[C]//Proceedings of the AAAI conference on artificial intelligence. 2015, 29(1).
- [78]. JI G, LIU K, HE S, et al. Knowledge graph completion with adaptive sparse transfer matrix[C]//Proceedings of the AAAI conference on artificial intelligence. 2016, 30(1).
- [79]. LIU Y, MA Y, MAO Z, et al. TD-GAT: Graph neural network for fault diagnosis knowledge graph[C]//2021 China Automation Congress (CAC). IEEE, 2021: 1734-1739.
- [80]. CHAO L, HE J, WANG T, et al. Pairre: Knowledge graph embeddings via paired relation vectors[J]. arXiv preprint arXiv:2011.03798, 2020.
- [81]. SUN Z, DENG Z H, NIE J Y, et al. Rotate: Knowledge graph embedding by relational rotation in complex space[J]. arXiv preprint arXiv:1902.10197, 2019.
- [82]. HUANG X, TANG J, TAN Z, et al. Knowledge graph embedding by relational and entity rotation[J]. Knowledge-Based Systems, 2021, 229: 107310.
- [83]. ZHANG S, TAY Y, YAO L, et al. Quaternion knowledge graph embeddings[J]. Advances in neural information processing systems, 2019, 32.
- [84]. ZHANG Z, CAI J, ZHANG Y, et al. Learning hierarchy-aware knowledge graph embeddings for link prediction[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(03): 3065-3072.
- [85]. HUANG Z, WANG D, HUANG B, et al. Concept2Box: Joint geometric embeddings for learning two-view knowledge graphs[J]. arXiv preprint arXiv:2307.01933, 2023.
- [86]. GUO Q, ZHUANG F, QIN C, et al. A survey on knowledge graph-based recommender systems[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 34(8): 3549-3568.
- [87]. 张小婉,邓秋军,柳先辉.结合图注意力机制的知识图谱推荐算法[J].计算机科学,2023,50(S2):464-470.60. ZHANG X W,DENG Q J,LIU X H.Knowledge graph recommendation algorithm combined with graph attention mechanism[J].Computer Science,2023,50(S2):464-470.60.
- [88]. WANG J, CHEN C, ZHENG Z, et al. DsMtGCN: A Direction-sensitive Multi-task framework for Knowledge Graph Completion[J]. arXiv preprint arXiv:2306.10290, 2023.
- [89]. XIAO Y, CHEN G, DU C, et al. A Study on Double-Headed Entities and Relations Prediction Framework for Joint Triple Extraction[J]. Mathematics, 2023, 11(22): 4583.
- [90]. 张彬,祖后敏,吴姣.融合社交关系和知识图谱的双图注意力推荐模型[J/OL].现代情报, 1-16[2025-03-24].<http://kns.cnki.net/kcms/detail/22.1182.G3.20241008.1103.004.html>.
- ZHANG B,ZU H M,WU J.Dual-Graph attention network recommendation algorithm combining social relationship and knowledge graph[J/OL].Journal of Modern Information,1-16[2025-03-24].<http://kns.cnki.net/kcms/detail/22.1182.G3.20241008.1103.004.html>.
- [91]. SHIMAOKA S, STENETORP P, INUI K, et al. An attentive neural architecture for fine-grained entity type classification[J]. arXiv preprint arXiv:1604.05525, 2016.
- [92]. JIN H, HOU L, LI J, et al. Fine-grained entity typing via hierarchical multi graph convolutional networks[C]//Proceedings of the 2019 conference on empirical methods in Natural Language Processing and the 9th International joint conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 4969-4978.

- [93]. LI H, WANG Y, ZHANG S, et al. KG4Vis: A knowledge graph-based approach for visualization recommendation[J]. IEEE Transactions on Visualization and Computer Graphics, 2021, 28(1): 195-205.
- [94]. ZHANG R, MA H, LI Q, et al. FIRE: knowledge-enhanced recommendation with feature interaction and intent-aware attention networks[J]. Applied Intelligence, 2023, 53(13): 16424-16444.
- [95]. LUO H, YANG Y, YAO T, et al. Text2nkg: Fine-grained n-ary relation extraction for n-ary relational knowledge graph construction[J]. Advances in Neural Information Processing Systems, 2024, 37: 27417-27439.
- [96]. WANG H, ZHANG F, WANG J, et al. Ripplenet: Propagating user preferences on the knowledge graph for recommender systems[C]//Proceedings of the 27th ACM international conference on information and knowledge management. 2018: 417-426.
- [97]. WANG H, ZHAO M, XIE X, et al. Knowledge graph convolutional networks for recommender systems[C]//The world wide web conference. 2019: 3307-3313.
- [98]. 徐春,王萌萌,孙彬.融合知识图谱和图注意力网络的旅游推荐算法[J].计算机工程与设计,2024,45(05):1420-1427.DOI:10.16208/j.issn1000-7024.2024.05.019.
- XU C,WANG M M,SUN B.Tourism recommendation algorithm based on knowledge graph and graph attention network[J].Computer Engineering and Design,2024,45(05):1420-1427.DOI:10.16208/j.issn1000-7024.2024.05.019.
- [99]. TING H, JIA Y, LIANSHAN Y, et al. Adaptive mesh partitioning for graph attention Transformer networks[J]. Opto-Electronic Engineering, 2025, 52(4): 250058-1-250058-12.
- [100]. JIANG Y, YANG Y, XIA L, et al. Diffkg: Knowledge graph diffusion model for recommendation[C]//Proceedings of the 17th ACM international conference on web search and data mining. 2024: 313-321.
- [101]. LIN Y, DU S, ZHANG Y, et al. A recommendation strategy integrating higher-order feature interactions with knowledge graphs[J]. IEEE Access, 2022, 10: 119290-119300.
- [102]. KATO T, KASHIMA H, SUGIYAMA M, et al. Multi-task learning via conic programming[J]. Advances in Neural Information Processing Systems, 2007, 20.
- [103]. LIU A A, SU Y T, NIE W Z, et al. Hierarchical clustering multi-task learning for joint human action grouping and recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(1): 102-114.
- [104]. ZHANG X, ZHANG X, LIU H. Self-Adapted Multi-Task Clustering[C]//IJCAI. 2016: 2357-2363.
- [105]. ZHENG Z, WANG Y, DAI Q, et al. Metadata-driven Task Relation Discovery for Multi-task Learning[C]//IJCAI. 2019: 4426-4432.
- [106]. WANG H, ZHANG F, ZHAO M, et al. Multi-task feature learning for knowledge graph enhanced recommendation[C]//The world wide web conference. 2019: 2000-2010.
- [107]. WANG Y Q, DONG L Y, LI Y L, et al. Multitask feature learning approach for knowledge graph enhanced recommendations with RippleNet[J]. Plos one, 2021, 16(5): e0251162.
- [108]. YANG B, YE H, MENG X. A Study of Multi-Task Recommendation Models Incorporating Preference Propagation[C]//2023 IEEE 3rd International Conference on Electronic Technology, Communication and Information (ICETCI). IEEE, 2023: 1827-1832.
- [109]. 方宝,王亮. 基于多模态特征融合的多任务学习推荐[J]. 物联网技术,2023,13(11):78-80. DOI:10.16667/j.issn.2095-1302.2023.11.021.
- FANG B,WANG L.Multi task learning recommendation based on multimodal feature fusion[J].Internet of Things Technologies,2023,13(11):78-80. DOI:10.16667/j.issn.2095-1302.2023.11.021.
- [110]. MARKOWITZ E, JIANG Z, YANG F, et al. Multi-Task Knowledge Enhancement for Zero-Shot and Multi-Domain Recommendation in an AI Assistant Application[J]. arXiv preprint arXiv:2306.06302, 2023.
- [111]. JIANG M, LI M, CAO W, et al. Multi-task convolutional deep neural network for recommendation based on knowledge graphs[J]. Neurocomputing, 2025, 619: 129136.

- [112]. CAO K, YOU J, LESKOVEC J. Relational multi-task learning: Modeling relations between data and tasks[J]. arXiv preprint arXiv:2303.07666, 2023.
- [113]. YANG Y, HUANG C, XIA L, et al. Knowledge graph contrastive learning for recommendation[C]//Proceedings of the 45th international ACM SIGIR conference on research and development in information retrieval. 2022: 1434-1443.
- [114]. MA J, ZHAO Z, YI X, et al. Modeling task relationships in multi-task learning with multi-gate mixture-of-experts[C]//Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining. 2018: 1930-1939.
- [115]. TANG H, LIU J, ZHAO M, et al. Progressive layered extraction (ple): A novel multi-task learning (mtl) model for personalized recommendations[C]//Proceedings of the 14th ACM Conference on Recommender Systems. 2020: 269-278.
- [116]. WANG Z, TSVETKOV Y, FIRAT O, et al. Gradient vaccine: Investigating and improving multi-task optimization in massively multilingual models[J]. arXiv preprint arXiv:2010.05874, 2020.
- [117]. IHUANG R, HAN C, CUI L. Entity-aware collaborative relation network with knowledge graph for recommendation[C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management. 2021: 3098-3102.
- [118]. ZHANG C, WANG Y, ZHU L, et al. Multi-graph heterogeneous interaction fusion for social recommendation[J]. ACM Transactions on Information Systems (TOIS), 2021, 40(2): 1-26.
- [119]. YANG Q, ZHANG Q, ZHANG C, et al. Interpretable relation learning on heterogeneous graphs[C]//Proceedings of the Fifteenth ACM International Conference on Web Search and Data Mining. 2022: 1266-1274.
- [120]. HOU Y, HE Z, MCAULEY J, et al. Learning vector-quantized item representation for transferable sequential recommenders[C]//Proceedings of the ACM Web Conference 2023. 2023: 1162-1171.
- [121]. FRIEDMAN L, AHUJA S, ALLEN D, et al. Leveraging large language models in conversational recommender systems[J]. arXiv preprint arXiv:2305.07961, 2023.
- [122]. XI Y, LIU W, LIU J, et al. Towards open-world recommendation with knowledge augmentation from large language models[C]//Proceedings of the 18th ACM Conference on Recommender Systems. 2024: 12-22.
- [123]. ZHAI J, ZHENG X, WANG C D, et al. Knowledge prompt-tuning for sequential recommendation[C]//Proceedings of the 31st ACM international conference on multimedia. 2023: 6451-6461.
- [124]. YANG R, FANG L, ZHOU Y Cpkgc: Constrained-prompt knowledge graph completion with large language models[J]. arXiv preprint arXiv:2310.08279, 2023.
- [125]. LU Y, WANG J. KARMA: Leveraging Multi-Agent LLMs for Automated Knowledge Graph Enrichment[J]. arXiv preprint arXiv:2502.06472, 2025.
- [126]. GAO J, ZOU X, AI Y I, et al. Graph Counselor: Adaptive Graph Exploration via Multi-Agent Synergy to Enhance LLM Reasoning[J]. arXiv preprint arXiv:2506.03939, 2025.
- [127]. RASMUSSEN P, PALIYCHUK P, BEAUVAIS T, et al. Zep: a temporal knowledge graph architecture for agent memory[J]. arXiv preprint arXiv:2501.13956, 2025.
- [128]. 沈希宇, 蔡肖红, 曹慧. 融合医疗知识图谱的推荐系统研究进展[J]. 计算机工程与应用, 2023, 59(19): 40-51.
- SHEN X Y, CAI X H, CAO H. Research progress of recommendation system based on medical knowledge graph[J]. Computer Engineering and Applications, 2023, 59(19): 40-51.
- [129]. ZHOU K, YU H, ZHAO W X, et al. Filter-enhanced MLP is all you need for sequential recommendation[C]//Proceedings of the ACM web conference 2022. 2022: 2388-2399.
- [130]. GONG F, WANG M, WANG H, et al. SMR: medical knowledge graph embedding for safe medicine recommendation[J]. Big Data Research, 2021, 23: 100174.
- [131]. 吴菊华, 李俊锋, 陶雷. 基于知识图谱嵌入与深度学习的药物不良反应预测[J]. 广东工业大学学报, 2024, 41(1): 19-26, 40. DOI:10.12052/gdutxb.230031.

- WU J H, LI J F, TAO L. Prediction of adverse drug reactions based on knowledge graph embedding and deep learning[J]. Journal of Guangdong University of Technology, 2024, 41(1): 19-26, 40. DOI: 10.12052/gdutxb.230031.
- [132]. 刘世雄, 熊旺平. 基于知识图谱的中成药用药监测系统设计与实现[J]. 现代信息科技, 2023, 7(13): 145-148, 152. DOI: 10.19850/j.cnki.2096-4706.2023.13.030.
- LIU S X, XIONG W P. Design and implementation of drug monitoring system for Chinese patent medicine based on knowledge graph[J]. Modern Information Technology, 2023, 7(13): 145-148, 152. DOI: 10.19850/j.cnki.2096-4706.2023.13.030.
- [133]. 张文卓. 基于知识图谱的药品推荐系统的研究与实现[D]. 河北工程大学, 2022. DOI: 10.27104/d.cnki.ghbjy.2022.000474.
- ZHANG W Z. Research and implementation of drug recommendation system based on knowledge graph[D]. Hebei University of Engineering, 2022. DOI: 10.27104/d.cnki.ghbjy.2022.000474.
- [134]. XU Z, WANG H, LIU X, et al. Causal Reasoning Model Based on Medical Knowledge Graph for Disease Diagnosis[M]//Modern Management based on Big Data II and Machine Learning and Intelligent Systems III. IOS Press, 2021: 481-487.
- [135]. 张文卓, 申艳光, 李焰. 融合知识图谱与协同过滤的药品推荐算法[J]. 软件导刊, 2023, 22(8): 42-47. DOI: 10.11907/rjdk.222069.
- ZHANG W Z, SHEN Y G, LI Y. Drug recommendation algorithm integrating knowledge graph and collaborative filtering[J]. Software Guide, 2023, 22(8): 42-47. DOI: 10.11907/rjdk.222069.
- [136]. ASHRAF M U, NAEEM M, JAVED A, et al. H2E: A Privacy Provisioning Framework for Collaborative Filtering Recommender System[J]. International Journal of Modern Education and Computer Science, 2019, 11(9): 1.
- [137]. ZHAO Z. Analysis on the "Douyin (TikTok) Mania" phenomenon based on recommendation algorithms[C]//E3S Web of Conferences. EDP Sciences, 2021, 235: 03029.
- [138]. ZHU H, LI X, ZHANG P, et al. Learning tree-based deep model for recommender systems[C]//Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining. 2018: 1079-1088.
- [139]. HAN H, WANG Y, SHOMER H, et al. Retrieval-augmented generation with graphs (graphrag)[J]. arXiv preprint arXiv:2501.00309, 2024.
- [140]. GUO Z, XIA L, YU Y, et al. Lightrag: Simple and fast retrieval-augmented generation[J]. arXiv preprint arXiv:2410.05779, 2024.
- [141]. ZHAO Q, QIAN H, LIU Z. Breaking the barrier: utilizing large language models for industrial recommendation systems through an inferential knowledge graph[C]//Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. 2024: 5086-5093.
- [142]. LIU B, FANG Y, XU N, et al. Large Language Models for Knowledge Graph Embedding: A Survey[J]. Mathematics, 2025, 13(14): 2244.
- [143]. ATTRIA, BHATTACHARYA P, et al. Why We Feel What We Feel: Joint Detection of Emotions and Their Opinion Triggers in E-commerce[J]. arXiv preprint arXiv:2507.04708, 2025.